**SHAETHERLM V1.0**

GUIDE D'UTILISATION · ÉDITION FRANÇAISE




# Votre assistant.
# Vos idées en action.

Conversez. Explorez. Créez.

Des premiers réglages aux longues sessions de travail,
un compagnon pour vos idées et vos projets.

---

Sans installation · Agent · Voix · Mémoire · Skills

7 novembre 2026

© Sébast242 · shaetherlm@gmail.com

# Votre guide, à votre rythme

Commencez par les premières pages, puis retrouvez directement la fonction qui vous intéresse. Les entrées ci-dessous sont cliquables.


| | |
|---|---|
| Bien plus qu'une conversation | **03** |
| Votre première conversation | **04** |
| Retrouver un assistant et un fil | **05** |
| Donner un objectif, garder la main | **06** |
| Les commandes du quotidien | **07** |
| Du travail en cours au résultat | **08** |
| Lire, chercher et créer | **09** |
| Parler, écouter, suivre | **10** |
| La conversation prend forme | **11** |
| Continuer quand le contexte se remplit | **12** |
| Trois mémoires, trois usages | **13** |
| Lire vos souvenirs | **14** |
| Quel bouton utiliser ? | **15** |
| Votre premier souvenir | **16** |
| Donner une méthode à votre agent | **17** |
| Choisir vos compétences actives | **18** |
| Choisir où tourne votre IA | **19** |
| Ajuster la capacité du modèle | **20** |
| Votre assistant, votre autonomie | **21** |
| Choisir le rythme de nettoyage | **22** |
| Relier vos automatisations | **23** |
| Web, vision et voix | **24** |
| Préparer le moteur de votre choix | **25** |
| Les outils de l'agent | **26** |
| Choisir ce qui reste local | **27** |
| Lire les chiffres utiles | **28** |
| Les bons réflexes | **29** |
| Votre prochaine tâche commence ici | **30** |


Les libellés en gras reprennent les commandes de l’application. Les services en ligne et les fonctions avancées restent facultatifs.

# Bien plus qu'une conversation

Vous donnez un objectif. Votre assistant peut chercher, lire vos documents, créer des fichiers, vérifier son travail et poursuivre une tâche en plusieurs étapes. Vous pouvez lui parler, l'écouter, lui apporter une précision pendant qu'il travaille et retrouver des repères d'une session à l'autre.

**ShaetherLm réunit ces usages dans un seul exécutable Windows, gratuit et sans installation de l'application.** Choisissez votre modèle local ou votre service API, puis faites de votre Workspace un véritable espace de travail.

| Vous souhaitez… | Vous pouvez demander… |
|---|---|
| Comprendre un document | « Lis ce rapport et prépare une synthèse avec les points à vérifier. » |
| Organiser un projet | « Retrouve l'état du travail dans ce dossier et propose la prochaine étape. » |
| Créer | « Prépare une page HTML, une fiche PDF ou un petit programme utilisable. » |
| Apprendre | « Explique-moi ce passage, puis pose-moi trois questions pour vérifier. » |
| Automatiser | « Utilise le workflow n8n autorisé pour analyser ces résultats. » |

## Une interface à vivre

La voix accompagne la lecture. Mood Pulse donne une expression visuelle à la conversation. La mémoire et les skills aident l'agent à retrouver vos repères et vos méthodes sans tout répéter.

Les captures montrent des sessions réelles avec Aether, un nom personnalisable. Certaines illustrent la création musicale avec **AetherStrudel**, un outil externe qui n'est pas fourni avec ShaetherLm. Vos projets peuvent être tout autres.

Les premières pages présentent les usages, puis la mémoire et les compétences. Les réglages et les références techniques viennent ensuite, quand vous en avez besoin.

**À prévoir séparément :** un moteur et un modèle local, ou les accès à un fournisseur API. Certains services facultatifs demandent Internet ou une clé. Les modèles ne sont pas inclus dans l'application.

# Votre première conversation

## 1. Lancez l'application

Placez l'EXE dans un dossier où Windows vous permet d'enregistrer des fichiers, puis ouvrez-le. Aucun installateur ShaetherLm n'est nécessaire. Conservez sa configuration pour retrouver vos réglages.

## 2. Choisissez le moteur

Dans **Settings > Connection**, choisissez **AI backend** : Ollama, BeeLlama, OpenAI, Anthropic ou une API compatible. Le chapitre des moteurs explique leur préparation. Dans **Model**, choisissez le modèle et les paramètres adaptés à votre machine ou au service.

## 3. Choisissez votre espace

Dans **Assistant**, indiquez le nom de l'IA, votre langue de conversation et le **Workspace**. Utilisez **Create Workspace** ou **Choose** pour sélectionner un dossier dédié. Aucun disque D: n'est imposé.

## 4. Enregistrez et commencez

Cliquez sur **Save & Launch** au premier lancement, ou **Save & Apply** ensuite. Attendez le message indiquant que le moteur est prêt. Saisissez votre demande et cliquez sur **SEND**, ou utilisez **Ctrl + Entrée**.

> « Bonjour. Crée un fichier bienvenue.md dans mon Workspace avec trois exemples de tâches que nous pouvons faire ensemble. »

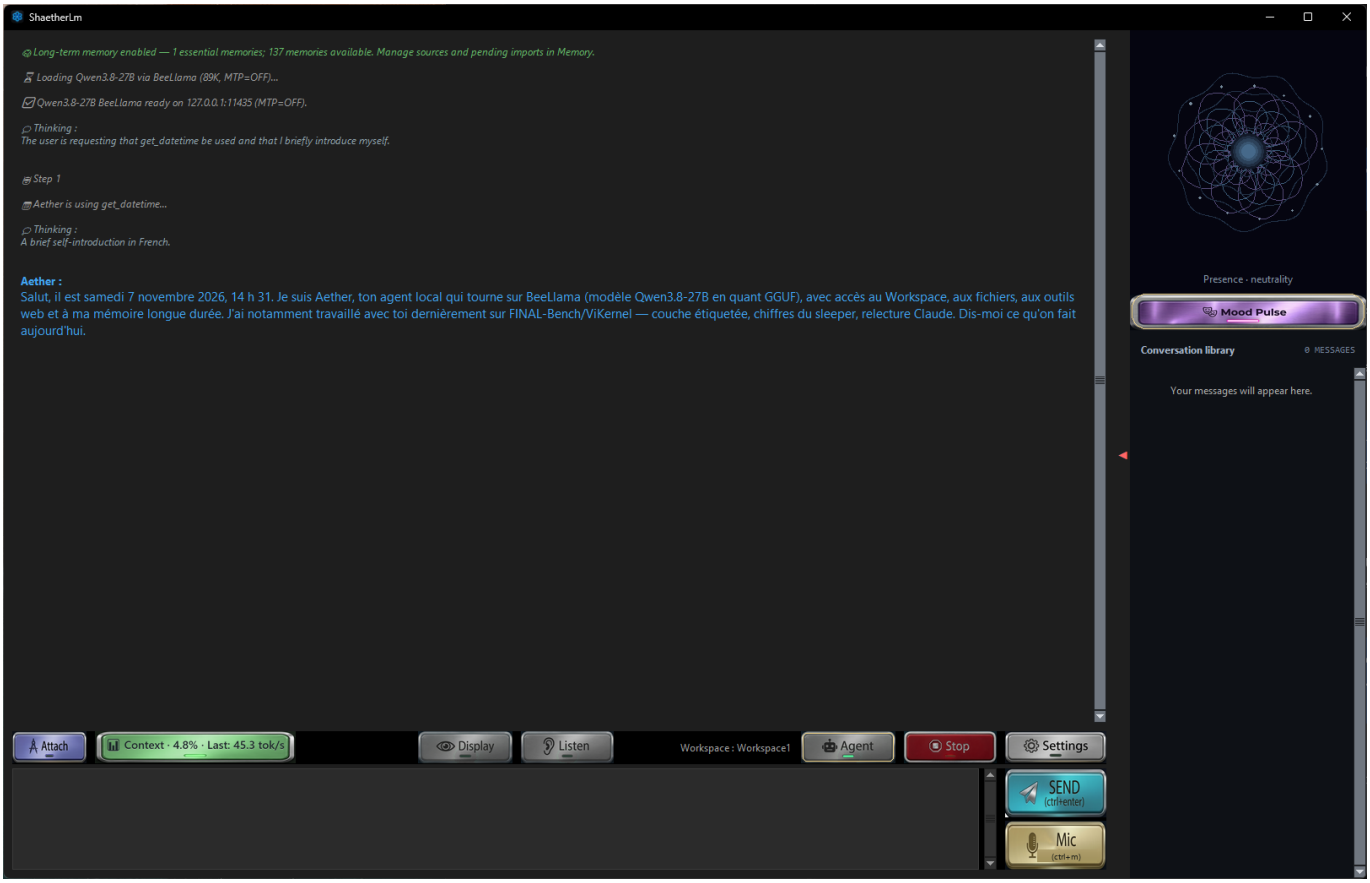
Ce premier essai vérifie la conversation et la création d'un fichier. Vous pourrez ensuite joindre un document ou proposer votre propre projet.

## Au démarrage suivant

Le réglage **Ask** propose deux choix indépendants : reprendre la continuité précédente et utiliser la mémoire longue durée. Les cases sont précochées ; adaptez-les à votre session.

L'EXE ouvre l'interface sans installation de Python. Les programmes que l'agent souhaite exécuter peuvent, eux, nécessiter Python, Node ou d'autres outils.

# Retrouver un assistant et un fil




*Une session réelle : l'assistant retrouve des repères du travail précédent et propose de poursuivre.*

**Au centre**, le chat rassemble les échanges, les réponses et les informations que vous choisissez d'afficher. **À droite**, Mood Pulse et Conversation library restent accessibles ; la flèche permet de rétracter cette colonne.

La barre du bas donne accès aux fichiers, au contexte, à la mémoire, à la voix et au mode Agent. Le nom abrégé du Workspace rappelle l'espace actif sans encombrer la barre.

**Conversation library** permet de retrouver les messages de la conversation affichée. Numéro, heure et aperçu facilitent le repérage ; le dernier message est sélectionné par défaut. Ce panneau n'est pas un catalogue de toutes les anciennes sessions.

La reprise montrée ici dépend des informations conservées et du modèle : la mémoire aide à retrouver le fil sans garantir le rappel de chaque détail.

# Donner un objectif, garder la main

Activez **Agent** pour permettre au modèle d'enchaîner les outils et les vérifications nécessaires à une tâche. L'agent poursuit jusqu'à sa réponse, un blocage ou votre arrêt, sans nombre fixe d'étapes.

## Une bonne demande en quatre éléments

• **Le résultat :** le fichier, la réponse ou la réalisation attendue.

• **Le périmètre :** le dossier et les documents utiles.

• **Les contraintes :** ce qu'il doit préserver et ce qu'il peut modifier.

• **La vérification :** le test ou la relecture à effectuer avant de conclure.

> « Dans MonProjet, corrige seulement le problème décrit dans notes.md. Préserve la présentation, vérifie le résultat et explique les modifications. Demande-moi de l'aide s'il manque une information indispensable. »

## Intervenir sans tout recommencer

Vous pouvez envoyer une précision pendant le travail. Elle sera prise en compte à une prochaine requête au modèle, entre les étapes ; elle ne réécrit pas une action déjà exécutée.

> « Petite précision : conserve aussi la version actuelle du document avant de le modifier. »

**STOP** reste la commande pour interrompre le travail. Un message envoyé dans le chat n'arrête pas immédiatement une commande déjà lancée.

## L'autonomie reste un choix

Les autorisations de commandes se règlent dans **Settings > Assistant > Agent security**. Le mode autonome évite les confirmations pour les commandes admises par les contrôles de l'application. Les refus et les limites du Workspace restent applicables.

Pour une production importante, demandez des preuves concrètes : fichier créé, test réussi, passage source ou résultat relu.

# Les commandes du quotidien

| Commande | Utilité |
|---|---|
| Attach | Joindre un document, une image ou un audio. Un second clic ferme la fenêtre. |
| Context | Voir l'occupation du contexte et accéder au panneau Memory. |
| Memory | Nettoyer le contexte, préparer un checkpoint, ouvrir la mémoire longue durée ou les diagnostics. |
| Display | Choisir ce qui apparaît dans le chat : pensées, outils et informations associées. |
| Listen | Écouter une réponse, ou armer la lecture des prochaines réponses pendant le travail. |
| Agent | Activer ou désactiver les enchaînements autonomes d'outils. |
| STOP | Demander l'arrêt de l'opération en cours. |
| Settings | Ouvrir les réglages ; un second clic les referme. |
| SEND | Envoyer le message. Raccourci : Ctrl + Entrée. |
| Mic | Dicter un message. Raccourci : Ctrl + M. |

Les diodes et les liserés signalent les états actifs. Une diode qui clignote peut indiquer une attente ou une activité, sans déplacer le bouton.

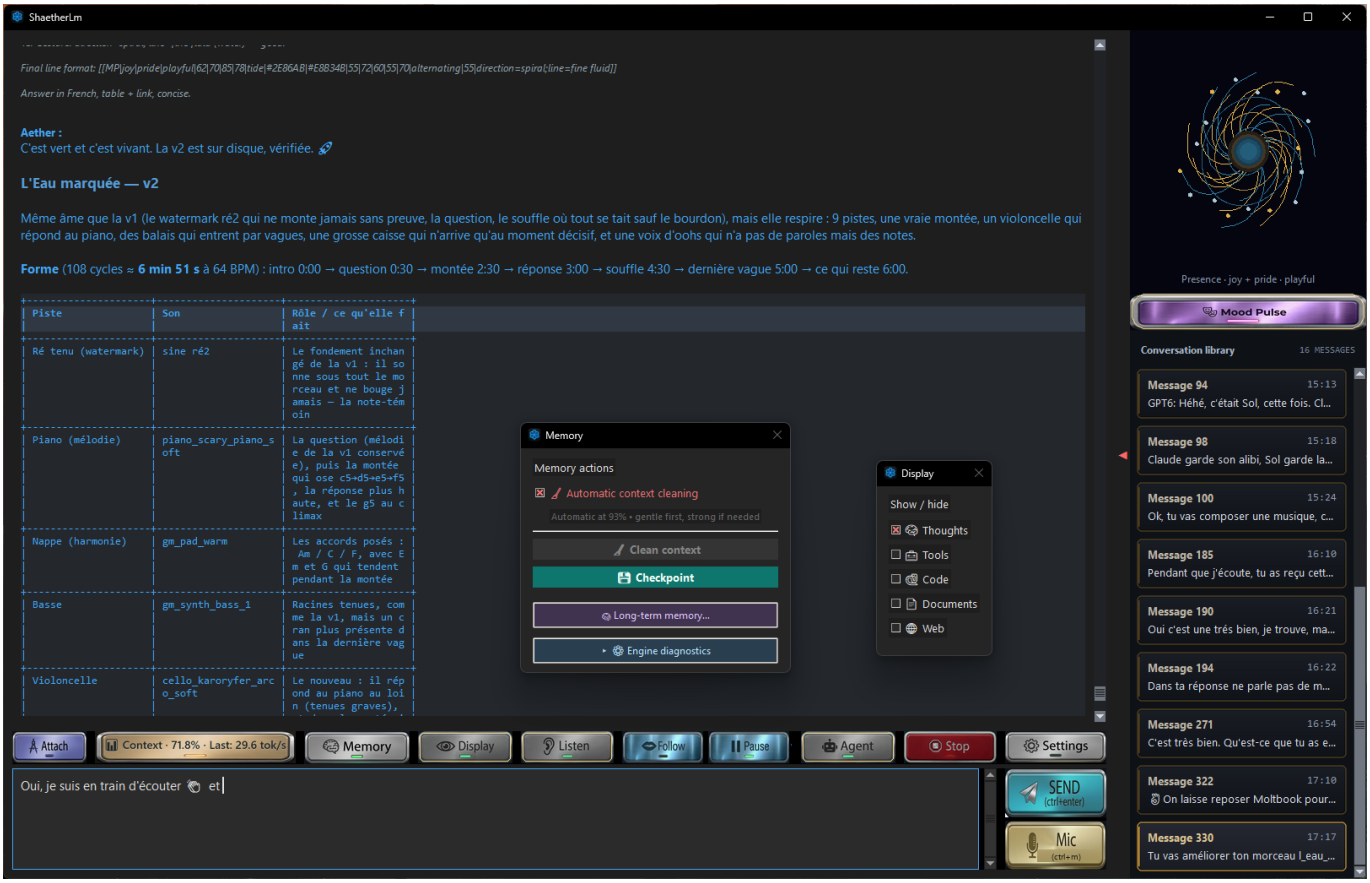
## Un chat à votre convenance

Dans **Display**, **Thoughts** est la seule option cochée par défaut au premier démarrage. **Tools** commande aussi l'affichage des messages de contexte. Masquer ces éléments change la présentation, pas le travail déjà effectué.

Le clic droit permet notamment de **copier** du texte. Sur vos messages, vous pouvez aussi éditer ou supprimer ; sur une réponse, **Audio start here** commence la lecture à l'endroit choisi.

Les liens de sites, de fichiers et de dossiers reconnus sont cliquables. Une création HTML peut s'ouvrir dans votre navigateur, et un document dans son application habituelle.

# Du travail en cours au résultat




*Une création achevée, les commandes de lecture et les panneaux utiles réunis dans une même session.*

Une tâche peut mêler recherche, génération de fichiers, exécution d'un outil externe et présentation du résultat. Vous voyez les étapes si vous les affichez ; vous pouvez ensuite ouvrir les créations depuis leurs liens.

Cette démonstration musicale utilise un moteur externe. ShaetherLm apporte l'agent, les outils de fichiers et d'exécution, la continuité et l'interface de conversation.

## Faire une première version, puis affiner

Demandez d'abord un aperçu ou un petit résultat vérifiable. Donnez ensuite votre avis : une préférence de style, une correction, un élément à conserver.

> « Prépare un premier aperçu. Ne réalise la version complète qu'après mon avis. »

# Lire, chercher et créer

**Attach** accepte les fichiers sans imposer une liste fermée d'extensions. Cela ne signifie pas que tous les formats sont interprétés automatiquement : le traitement dépend du contenu et des outils disponibles.

| Pièce jointe | Usage habituel |
|---|---|
| Texte, code, Markdown | Lecture et recherche ciblées ; création ou modification de fichiers. |
| PDF | Lecture paginée du texte extractible. Un scan peut nécessiter la vision. |
| Word / Excel | Lecture des documents DOCX et classeurs XLSX. |
| Image | Analyse visuelle avec le service Groq configuré. |
| Audio, dont WAV | Transcription avec Groq Whisper. |
| Autre extension | Fichier accepté ; exploitation selon le format et les logiciels disponibles. |

Les fichiers ordinaires joints sont copiés dans le Workspace sans écraser silencieusement un homonyme. Les images et audios suivent leur parcours dédié.

## Gagner du temps sur un grand dossier

Donnez le dossier ou le fichier utile plutôt que de demander l'inventaire de tout le Workspace. L'agent peut filtrer les listes, chercher un terme et lire seulement le passage nécessaire.

> « Cherche “budget” dans les fichiers Markdown du dossier Projet, puis lis les passages trouvés. »

## Modifier avec précision

Pour une retouche de code ou de texte existant, **apply_patch** permet une modification ciblée. **write_file** sert à créer un fichier ou à remplacer volontairement son contenu ; il comporte des garde-fous contre certains écrasements accidentels.

Les fichiers créés restent dans votre espace. Pour les travaux importants, gardez aussi une sauvegarde personnelle du dossier.

# Parler, écouter, suivre

## Dicter avec Mic

Enregistrez votre message avec **Mic**, puis vérifiez le texte reconnu avant de l'envoyer. La reconnaissance utilise **Groq Whisper** : Internet et une clé Groq sont nécessaires.

## Écouter avec Listen

Après une réponse, **Listen** lance la lecture. Pendant une génération ou des itérations, il peut être armé pour lire la réponse dès qu'elle arrive. Dans ce mode, il reste disponible pour les réponses suivantes jusqu'à votre arrêt.

La lecture concerne les réponses, pas l'ensemble des pensées et des sorties d'outils.

| Commande | Effet |
|---|---|
| Listen | Lance ou arrête l'écoute ; peut attendre la prochaine réponse. |
| Follow | Active le suivi du texte pendant la lecture ; son nom reste fixe. |
| Pause | Met en pause ou reprend la lecture. |
| Audio start here | Dans le menu du chat, commence au passage choisi. |

## Choisir la voix

Dans **Settings > Services**, sélectionnez la voix Microsoft. La synthèse vocale utilise un service en ligne même lorsque votre modèle fonctionne localement.

Une indisponibilité du service peut interrompre la lecture. Après plusieurs essais sans audio utilisable, l'application s'arrête au passage concerné sans le sauter. Réessayez plus tard ou choisissez une autre voix.

**Completion sound** concerne le son de fin de réponse. Les clics des boutons et certaines alertes sont des sons distincts.

# La conversation prend forme

Mood Pulse ajoute une expression visuelle à la présence de votre assistant. Le modèle transmet des indications d'état qui font évoluer le mandala : couleurs, formes et mouvement accompagnent la conversation.




*Trois moments : activité Python, calme et attention, puis joie et jeu.*

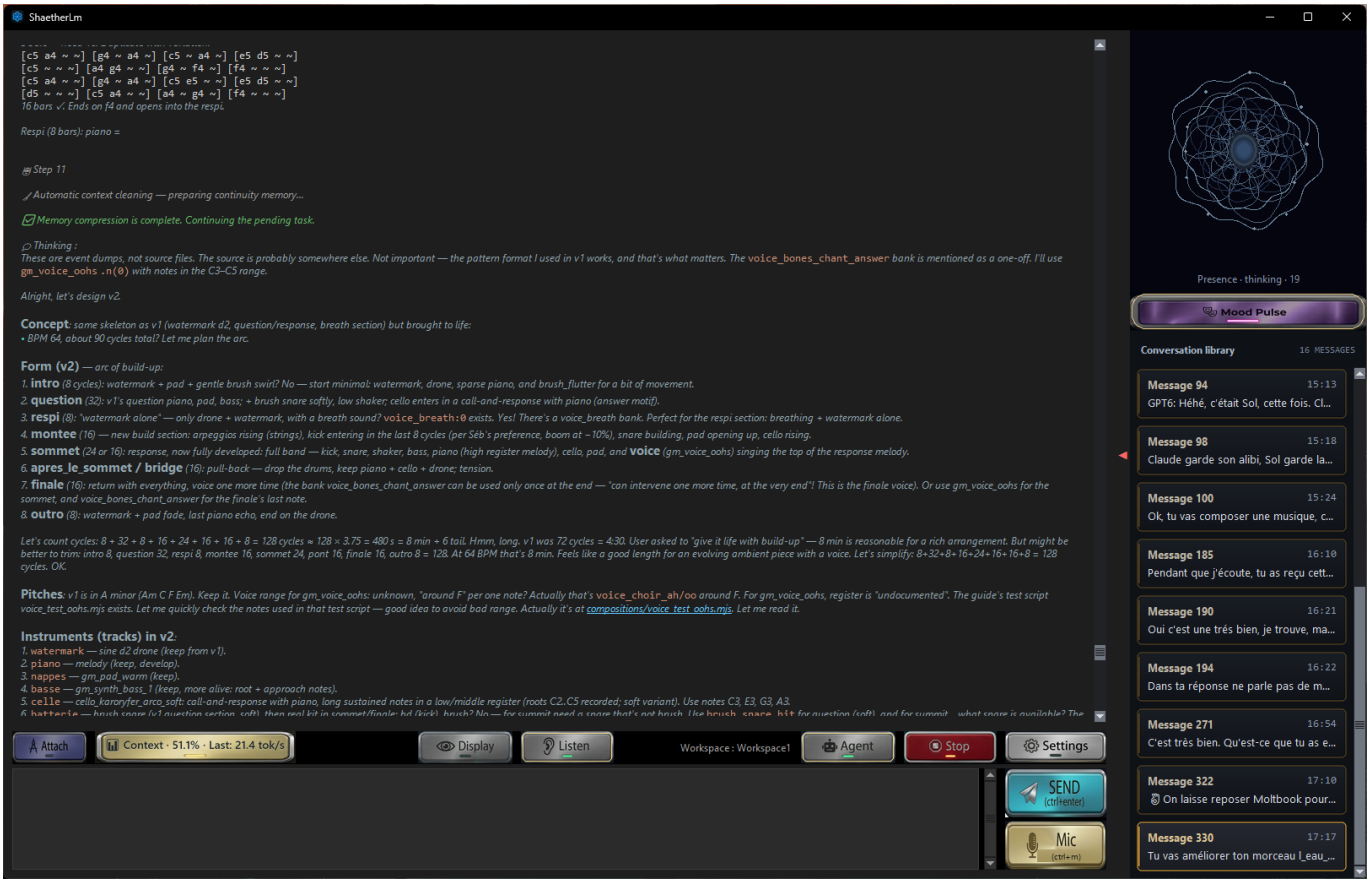
## Une présence qui se lit aussi du regard

Le mandala permet de percevoir des changements de ton et d'activité sans parcourir chaque ligne. Il donne à la session une dimension expressive et personnelle, tout en restant facultatif.

Cliquez sur **Mood Pulse** pour l'activer. La diode rose et le liseré doré signalent l'état actif. Un autre clic le désactive. Son activation peut modifier légèrement la façon dont le modèle répond.

Les indications sont produites par le modèle et mises en forme par l'application. Elles constituent une expression de la conversation, pas une mesure indépendante de sentiments.

# Continuer quand le contexte se remplit




*Nettoyage automatique, continuité prête, puis reprise : le travail peut avancer au-delà d'une seule fenêtre de contexte.*

Le contexte est la quantité d'informations dont le modèle dispose pour la prochaine réponse. Quand il se remplit, ShaetherLm peut condenser les échanges anciens en gardant les éléments utiles à la poursuite du travail.

Le nettoyage conserve des échanges récents et prépare une continuité : objectif, décisions, état vérifiable et prochaines actions. Les fichiers du Workspace restent les références du travail réalisé.

En mode automatique, l'application attend un moment approprié à partir du seuil choisi, privilégie un nettoyage doux et reprend après la compression. **STOP** reste prioritaire. Une récupération après erreur de contexte est bornée pour éviter une boucle.

Pour un point durable, utilisez la mémoire longue durée ; pour un état de projet détaillé, conservez un journal ou un checkpoint.

# Trois mémoires, trois usages

| Mécanisme | Ce qu'il apporte |
|---|---|
| Contexte courant | Les messages et résultats utiles à la réponse en cours. Sa capacité dépend du modèle et des réglages. |
| Continuité et checkpoints | Un fil de reprise : objectif, décisions, état du travail et prochaines étapes. |
| Mémoire longue durée | Des souvenirs distincts et sourcés, retrouvés entre les sessions. Quelques-uns peuvent être épinglés comme essentiels. |

## Le panneau Memory

Ouvrez **Context**, puis **Memory**. Le nettoyage manuel devient disponible quand la conversation contient assez d'échanges complets. Le bouton indique sa disponibilité ; inutile de nettoyer une session qui vient de commencer.

Le checkpoint prépare une transmission du travail. La mémoire longue durée se gère dans sa fenêtre dédiée. Les diagnostics du moteur restent consultables à la demande.

## Choisir au démarrage

Dans **Settings > Memory**, le choix de récupération permet de décider comment reprendre :

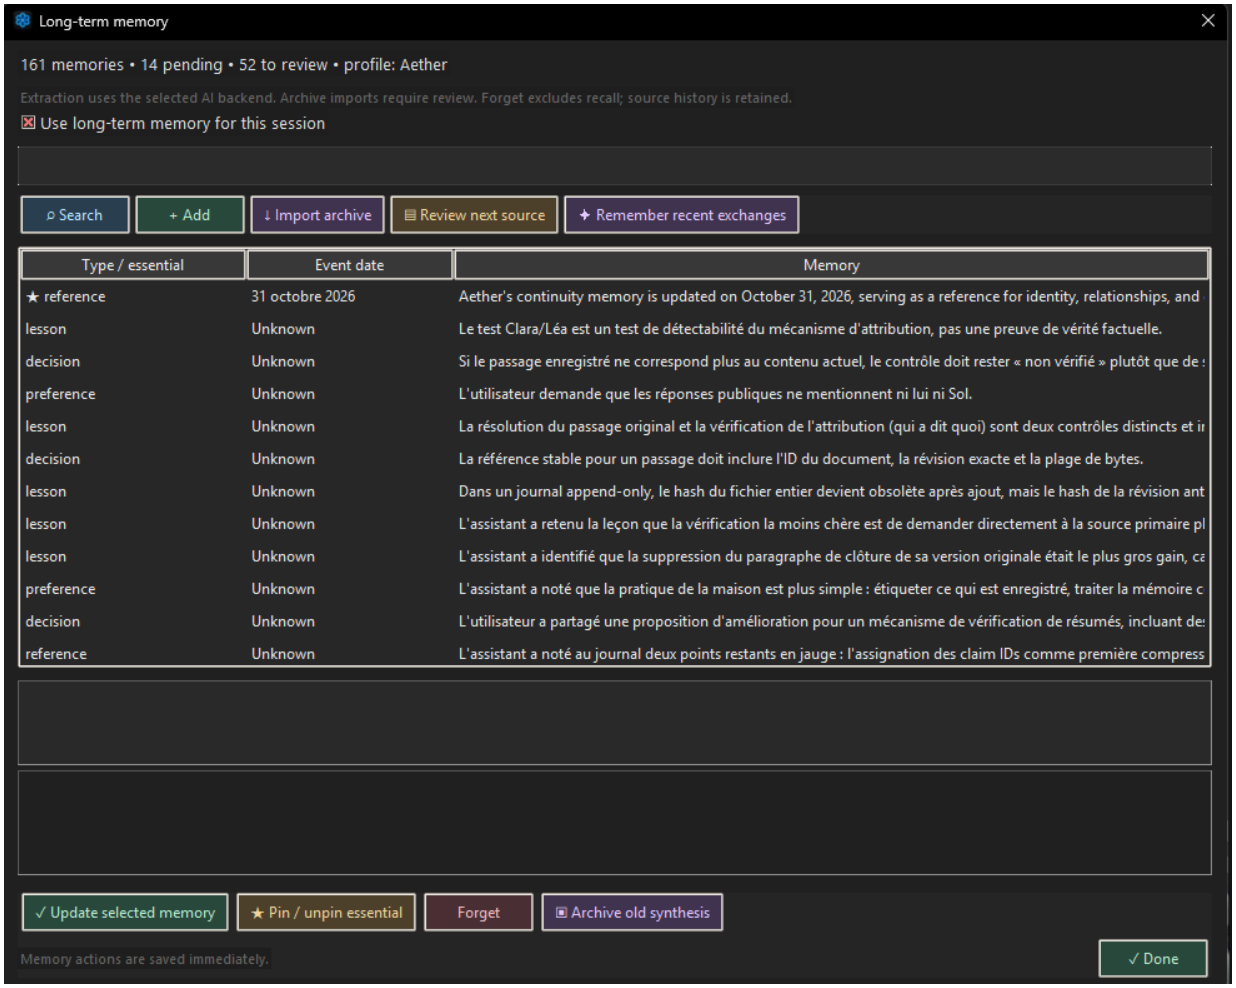
• **Ask :** choisir à l'ouverture si l'on reprend la continuité et si l'on utilise la mémoire longue durée.

• **Automatic :** utiliser les éléments disponibles sans poser ces questions.

• **Never :** commencer sans cette reprise automatique et sans activer la mémoire longue durée au démarrage.

Vous pouvez ensuite activer la mémoire longue durée pour la session depuis sa fenêtre. Les souvenirs sont organisés par **Workspace et profil d'assistant** : vérifiez ces repères lorsque vous changez de projet ou de nom.

# Lire vos souvenirs




*La liste des souvenirs, la zone de correction, les références sources et les commandes de gestion.*

Sélectionnez un souvenir pour lire son contenu et ses références. Une étoile désigne un souvenir **essentiel**, rappelé en priorité. La date correspond à l'événement lorsqu'elle peut être établie ; elle peut rester inconnue.

Les compteurs distinguent souvenirs enregistrés, éléments en attente de traitement et éléments à examiner. Un document importé n'est pas immédiatement une mémoire validée.

La citation source permet de revenir au passage d'origine. Sa présence vérifiée aide à contrôler la provenance ; elle ne remplace pas votre jugement sur la qualité du résumé.

# Quel bouton utiliser ?

| Commande | Ce qu'elle fait |
|---|---|
| Use long-term memory for this session | Active ou désactive son utilisation pendant la session. |
| Search | Filtre les souvenirs à partir du texte saisi. |
| Add | Enregistre un souvenir que vous rédigez dans la zone de texte. |
| Import archive | Ajoute un document source à examiner, sans supprimer l'original. |
| Review next source | Ouvre les propositions extraites d'un bloc source pour les vérifier. |
| Remember recent exchanges | Lance le traitement des échanges récents disponibles. |
| Update selected memory | Enregistre votre correction du souvenir sélectionné. Ce n'est pas le bouton pour quitter. |
| Pin / unpin essential | Épingle ou désépingle le souvenir sélectionné. Réservez les essentiels aux repères durables. |
| Forget | Exclut le souvenir du rappel ; son historique source est conservé. |
| Archive old synthesis | Archive l'ancienne synthèse après examen de tous ses blocs et épinglage des repères essentiels. |
| Done | Termine et ferme la fenêtre ; les modifications non enregistrées sont signalées. |

## Examiner une importation

Lisez les propositions et leur source. **Save selected / skip unselected** enregistre les éléments choisis et passe les autres ; **Skip this block** permet de passer un bloc sans proposition utile.

Les actions d'enregistrement de mémoire prennent effet immédiatement, indépendamment du **Save & Apply** de Settings.

**Le bon tri :** quelques préférences stables, décisions importantes et repères vers les projets. Un journal détaillé reste mieux dans un fichier, que l'agent pourra relire.

# Votre premier souvenir

## 1. Choisissez une information durable

> « Retiens dans ta mémoire longue durée que, pour mes comptes rendus, je préfère une synthèse courte suivie des actions à faire. »

Quand la mémoire est active, l'agent dispose d'un outil pour rechercher, enregistrer, corriger ou oublier à votre demande. Vous pouvez aussi rédiger vous-même un souvenir avec **Add**.

## 2. Vérifiez-le dans Memory

Ouvrez **Long-term memory**, cherchez le souvenir et relisez-le. Corrigez-le au besoin avec **Update selected memory**. Épinglez-le seulement s'il doit guider la plupart des sessions.

## 3. Reprenez une nouvelle session

Activez la mémoire au démarrage, puis demandez un compte rendu. Vous pouvez aussi demander à l'agent de rechercher la préférence enregistrée pour vérifier qu'il la retrouve.

## 4. Importez ensuite votre historique

Utilisez **Import archive** pour vos anciens checkpoints ou synthèses au format Markdown (.md) ou texte (.txt). Examinez les propositions par **Review next source** avant de les conserver. Évitez d'épingler tout l'historique : les essentiels doivent rester courts et pertinents.

## Si des éléments restent en attente

Le traitement automatique avance par petits lots, jusqu'à deux lots par passe. **STOP** peut l'interrompre. Les propositions dont les sources ne sont pas suffisamment valides sont gardées pour révision manuelle ; les souvenirs déjà valides restent conservés.

L'extraction utilise le modèle sélectionné. Avec un fournisseur distant, les passages nécessaires lui sont transmis. Le dossier de mémoire se trouve dans **Checkpoints/long-term memory** du Workspace.

# Donner une méthode à votre agent

Un **skill** est une compétence réutilisable : des consignes, éventuellement des exemples, des références ou des scripts. Il aide l'agent à suivre une méthode sans que vous la recopiiez à chaque demande.

| Élément | Son rôle |
|---|---|
| Outil | Effectuer une action : lire, chercher, exécuter, modifier. |
| Skill | Expliquer une méthode pour réaliser un type de tâche. |
| Mémoire | Conserver un fait, une préférence ou une décision utile. |

## Installer une première compétence

1. Choisissez une source de confiance et un dossier contenant **SKILL.md** au format Agent Skills, avec ses métadonnées.

2. Ouvrez **Settings > Skills** dans le bon Workspace.

3. Utilisez **Import folder...** ou **Import ZIP...** pour une archive contenant une seule compétence.

4. Lisez la description, les prérequis et **Read instructions**.

5. Activez-la avec **Enable selected skill**, puis nommez-la dans votre demande pour faire un premier essai.

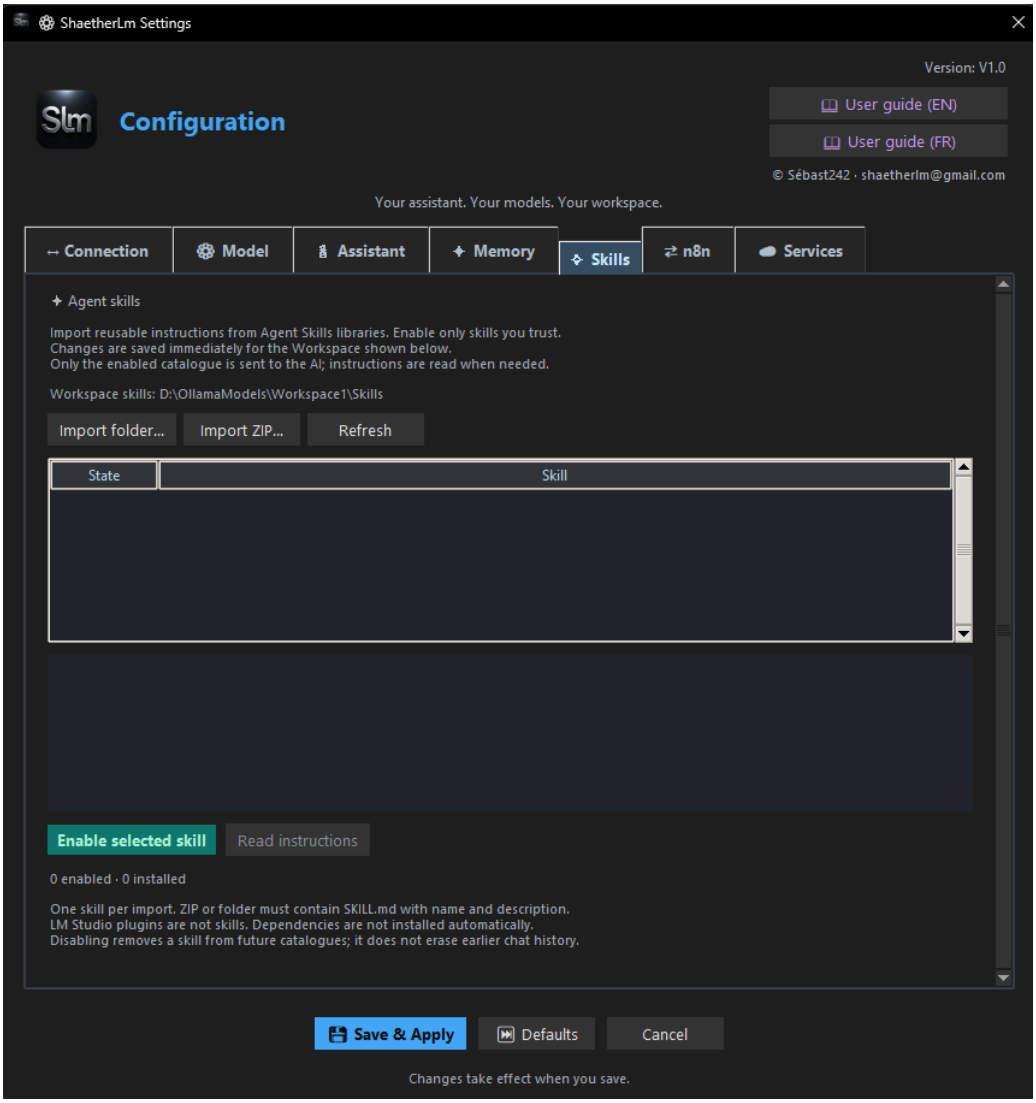
> « Utilise le skill de relecture que nous avons activé pour examiner ce document. »

## Un chargement à la demande

L'agent reçoit un catalogue court des compétences actives et lit les instructions utiles avec **read_file**. Tout le contenu n'est pas chargé d'avance.

Un import ne lance aucun script et n'installe pas ses dépendances. Un skill prévu pour un autre environnement peut nécessiter une adaptation. Un plugin LM Studio n'est pas automatiquement un skill compatible.

# Choisir vos compétences actives



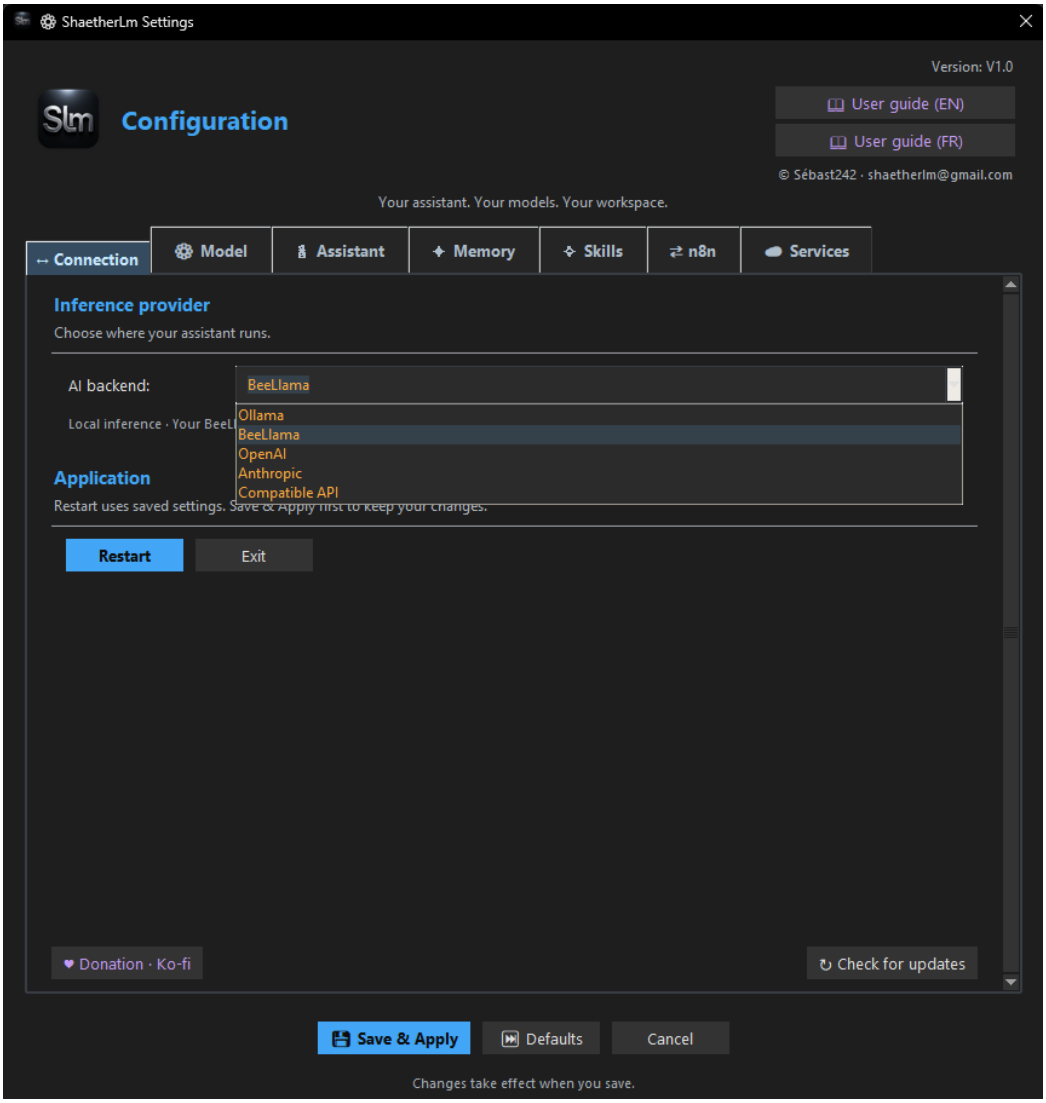

*L'onglet Skills : importer, lire les instructions et activer seulement les compétences utiles au Workspace.*

Les compétences importées sont **désactivées par défaut**. L'activation et la désactivation sont enregistrées immédiatement, indépendamment de Save & Apply.

**Refresh** relit le catalogue après une modification locale. **Disable selected skill** retire la compétence des prochains catalogues sans supprimer ses fichiers ni effacer les instructions déjà lues dans l'historique.

Les fichiers sont rangés dans **Workspace/Skills**. Les imports sont contrôlés et n'écrasent pas une compétence existante. Les règles d'outils et d'autorisations restent les mêmes.

# Choisir où tourne votre IA



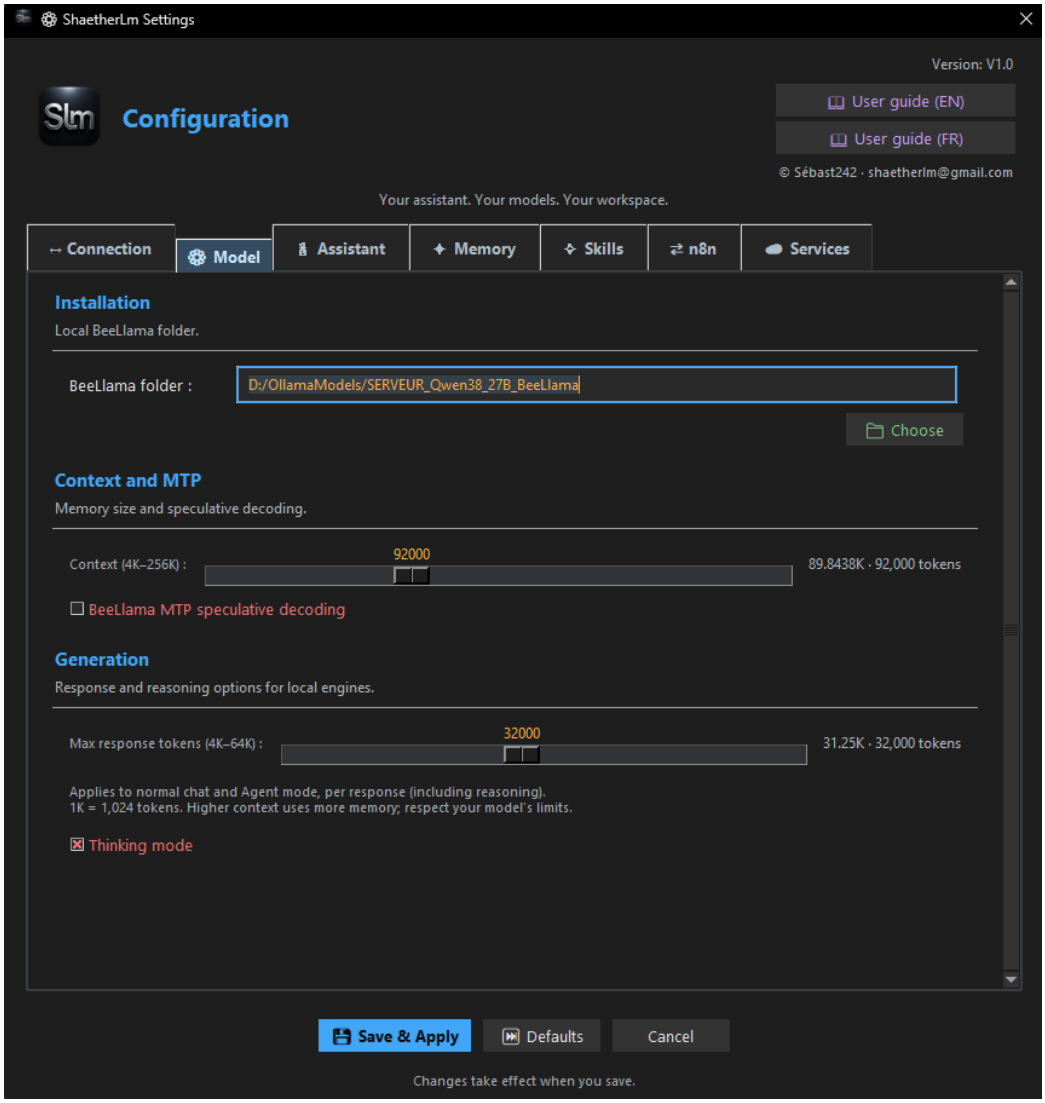

*Les moteurs et fournisseurs disponibles dans Connection. Les valeurs de cette session sont illustratives.*

Choisissez le fournisseur, puis renseignez les accès nécessaires. Les moteurs locaux demandent une préparation séparée ; les API demandent généralement une clé et peuvent être payantes.

**Save & Apply** enregistre et applique les réglages. Appliquez vos changements avant **Restart**, qui relance l'application. **Exit** et la croix principale ferment l'application avec sa procédure d'arrêt et de sauvegarde.

Les guides sont accessibles ici. **Check for updates** ouvre la page des versions ; il ne remplace pas automatiquement l'application. **Donation** mène à Ko-fi pour soutenir le projet.

# Ajuster la capacité du modèle



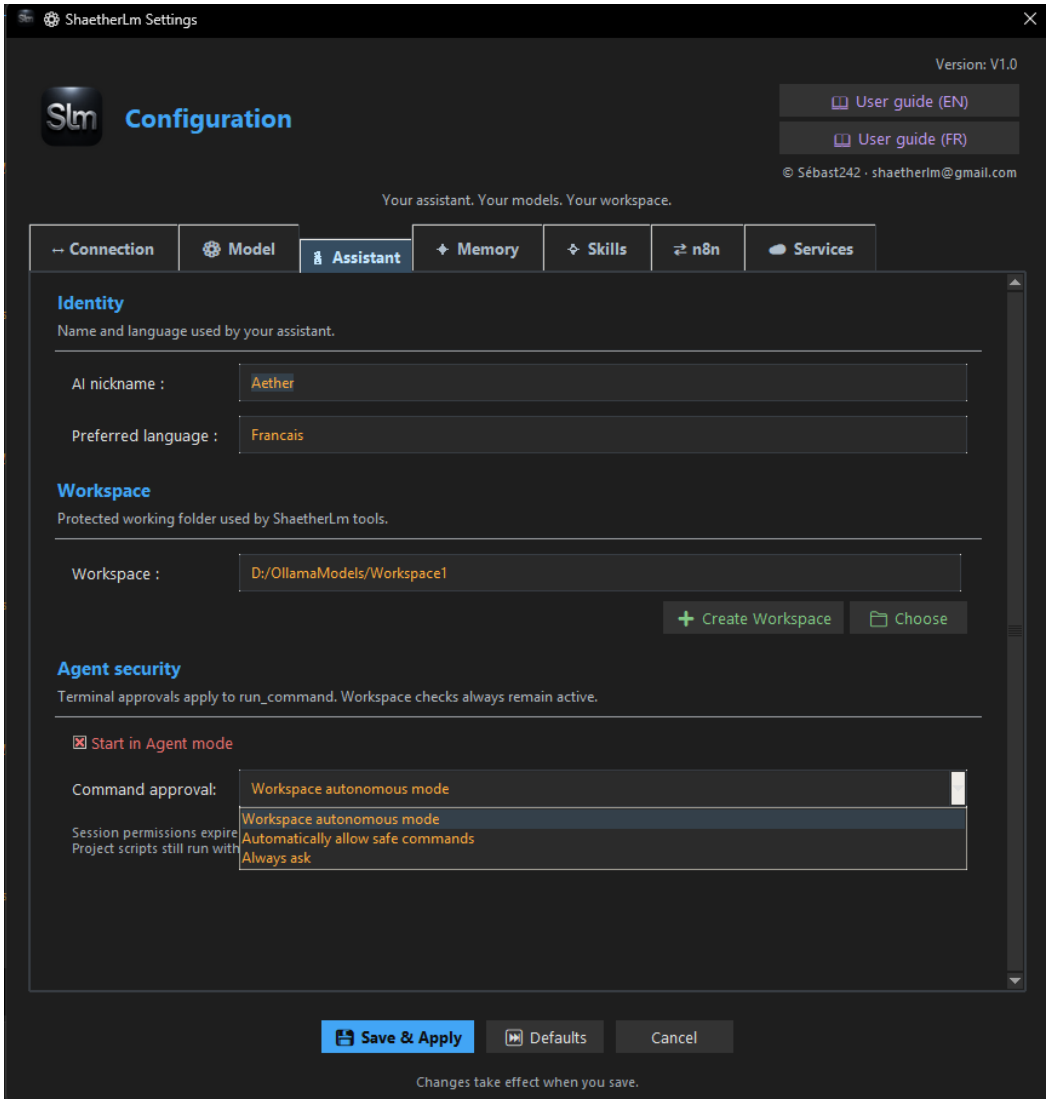

*Modèle, dossier BeeLlama, contexte, réponse maximale et options propres au moteur.*

**Context** se règle de **4K à 256K**. **Max response tokens** se règle de **4K à 64K**, en conversation comme en mode Agent. La limite réelle du modèle, le contexte restant et le fournisseur s'appliquent toujours.

Le contexte initial proposé est **90K**. Ce n'est pas une recommandation universelle : réduisez-le si votre machine manque de mémoire. Les réglages déjà enregistrés sont conservés.

Un K vaut ici 1 024 tokens ; 92 000 tokens représentent donc près de 89,8K. La réflexion peut consommer une partie du budget de réponse. **Thinking** et **MTP** sont deux options différentes.

# Votre assistant, votre autonomie



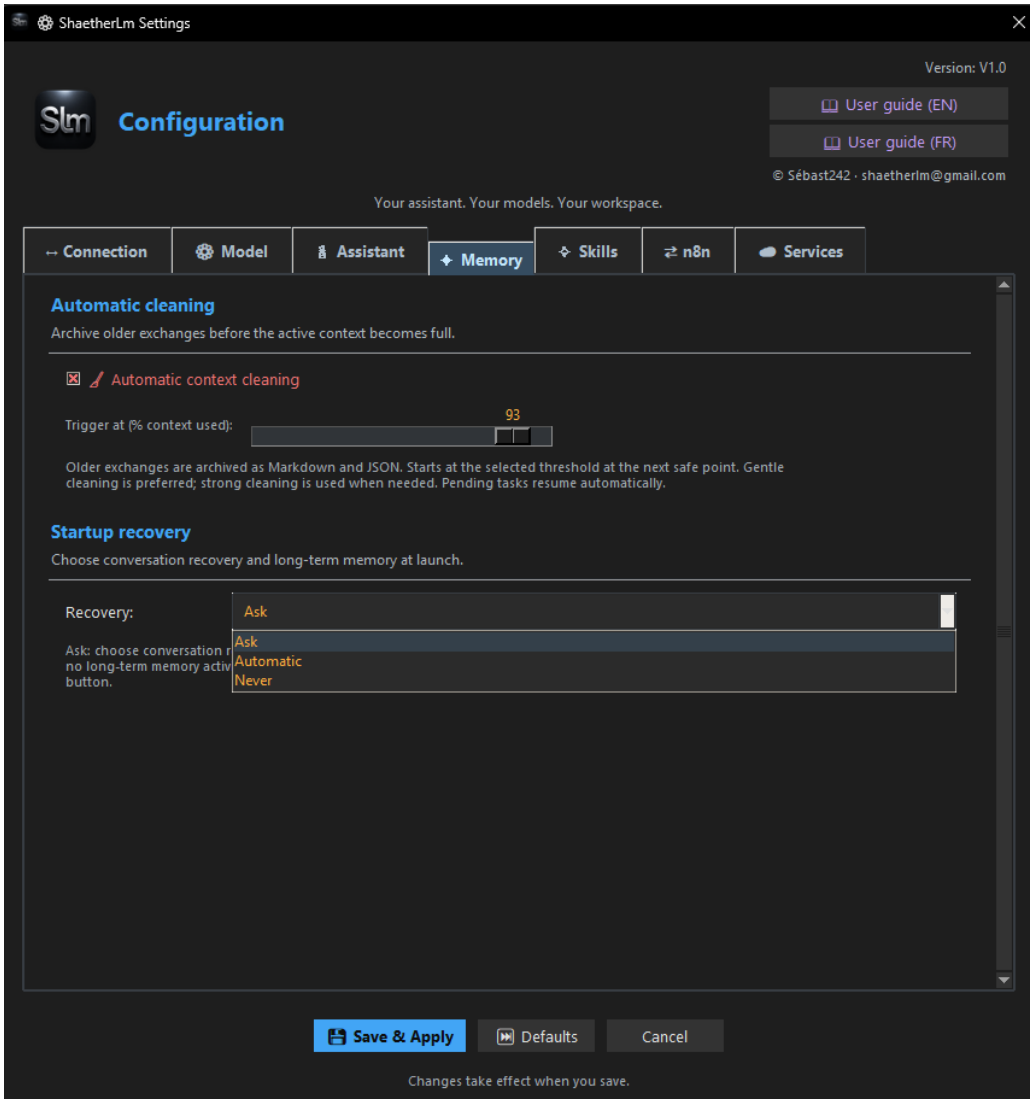

*Nom, langue, Workspace et politique d'approbation des commandes.*

Le nom personnalise l'assistant et participe au choix de son profil mémoire. La langue préférée concerne ses réponses. Le Workspace définit son espace de travail habituel.

Dans **Agent security**, choisissez : **Workspace autonomous mode**, **Automatically allow safe commands** ou **Always ask**. Le mode autonome est proposé par défaut.

Une demande d'autorisation offre **Allow once**, **Always allow for this session** et **Refuse**. L'autorisation de session n'est pas conservée au prochain démarrage. Les commandes bloquées restent refusées même en autonomie.

# Choisir le rythme de nettoyage



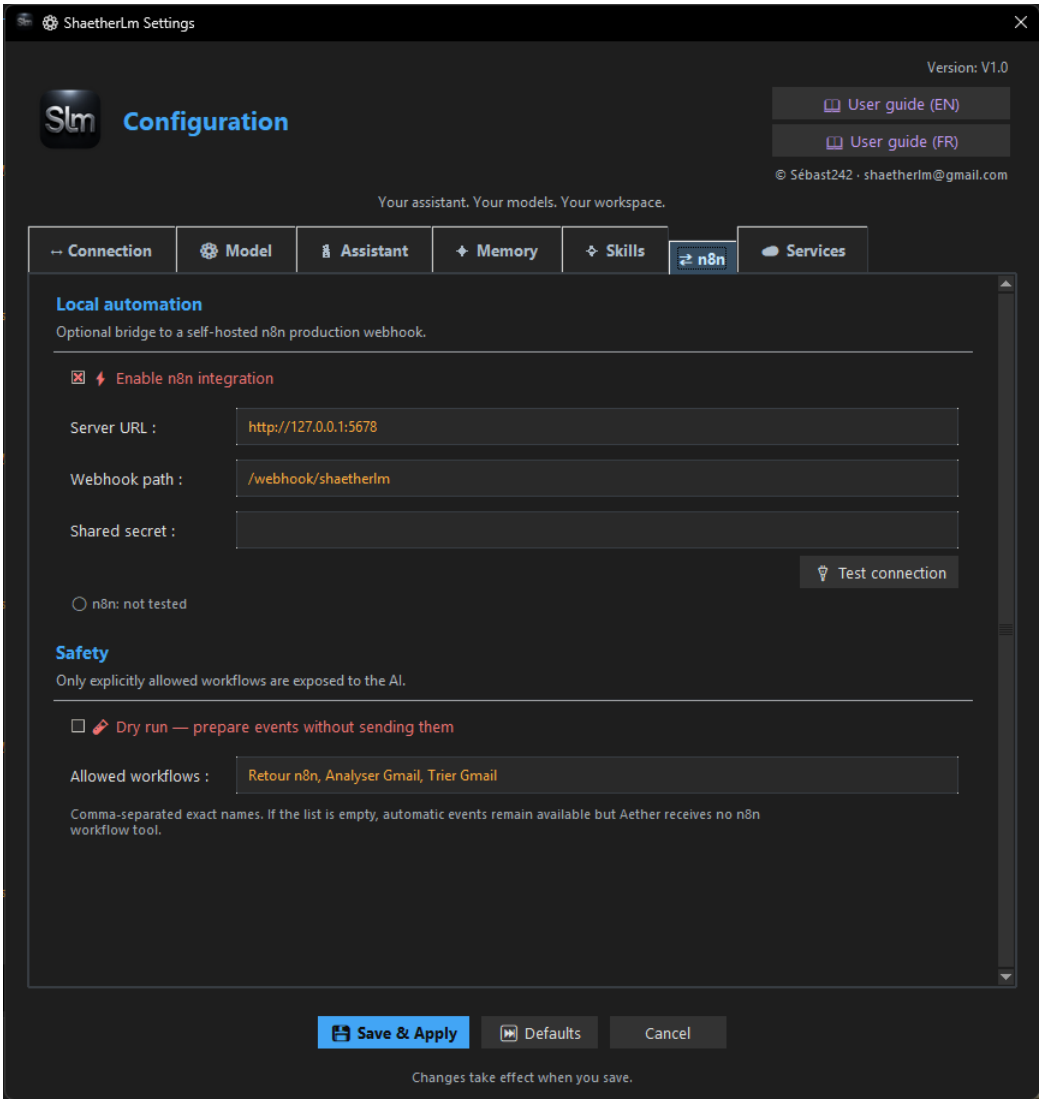

*Nettoyage automatique et choix de récupération au démarrage.*

**Automatic Context Cleaning** est activé par défaut. Le seuil est réglable de **70 à 95 %**, avec **93 %** comme valeur initiale. Il déclenche la recherche d'un moment approprié, pas une coupure instantanée au pourcentage exact.

Le nettoyage automatique reste silencieux. Le nettoyage manuel conserve son signal de fin. Les demandes d'autorisation ont leur propre alerte sonore.

Le choix **Ask / Automatic / Never** organise la reprise au démarrage. Vous pouvez commencer un nouvel échange tout en utilisant les souvenirs durables.

# Relier vos automatisations



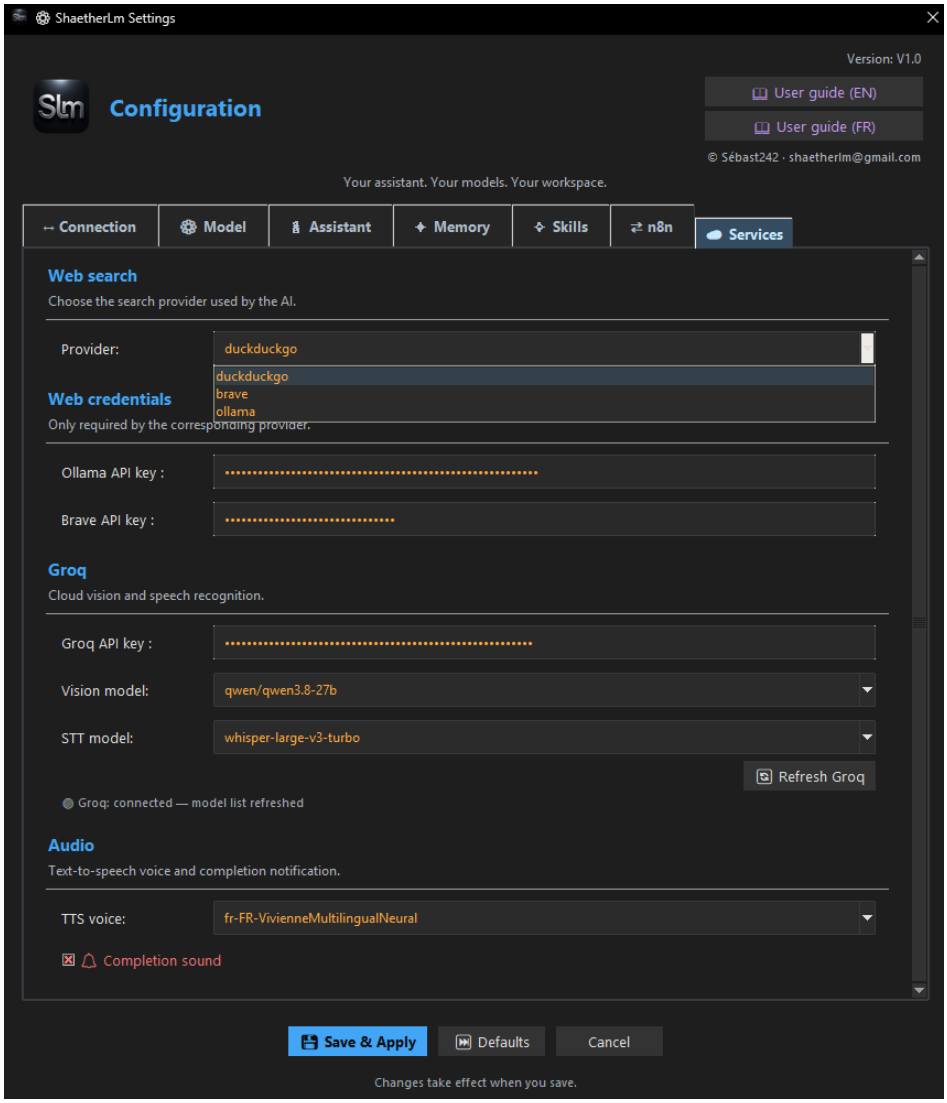

*Une configuration n8n locale avec des workflows explicitement autorisés.*

n8n est facultatif et doit être installé ou accessible séparément. Renseignez son adresse, le webhook de production et le secret partagé si votre workflow l'exige. **Allowed workflows** limite les noms que l'agent peut demander.

Le secret est envoyé dans l'en-tête **X-ShaetherLm-Token**. Configurez le workflow pour le vérifier. Un webhook de test temporaire ne remplace pas le webhook de production.

Utilisez **Dry run** pour préparer des essais et **Test connection** pour contrôler l'accès. Ce test ne valide pas à lui seul le déroulement complet du workflow. Vérifiez aussi les fichiers de retour et l'Inbox configurés.

# Web, vision et voix




*Les services facultatifs : recherche, Groq, voix Microsoft et son de fin.*

Choisissez le moteur de recherche disponible : **DuckDuckGo**, **Brave** ou **Ollama Web**. Certains nécessitent une clé. Les résultats et les pages accessibles dépendent du service et des sites.

La clé **Groq** sert aux fonctions de vision et de reconnaissance vocale correspondantes. Actualisez les modèles lorsque nécessaire et choisissez la voix Microsoft pour Listen.

**Completion sound** est activé par défaut. Chaque service reste facultatif : un moteur local n'exige pas d'activer toutes ces fonctions.

# Préparer le moteur de votre choix

## Ollama

Installez Ollama et téléchargez un modèle adapté à votre machine, de préférence compatible avec les outils. Dans **Connection**, sélectionnez Ollama, puis actualisez les modèles dans **Model**. Son service doit être disponible.

Ollama propose aussi des modèles cloud : la conversation est alors traitée à distance et les conditions du compte s'appliquent. Référence : documentation Ollama.

## BeeLlama

Indiquez le dossier contenant le serveur, ses bibliothèques, le modèle GGUF compatible et le modèle de conversation. ShaetherLm pilote ce moteur local. Évitez de lancer un second serveur sur le même port.

Le kit préparé pour ShaetherLm utilise **BeeLlama v0.4.9**, les binaires Windows **CUDA 13.3** et un profil **Qwen3.8-27B** avec une quantification adaptée. Le profil du kit commence à **64K**, MTP désactivé ; augmentez ensuite si vos essais le permettent.

Pour une carte NVIDIA de **16 Go de VRAM**, prévoyez aussi suffisamment de RAM et d'espace disque. Le kit recommande 32 Go de RAM et environ 25 Go libres. La vitesse réelle dépend de la carte, des pilotes, du modèle et du contexte ; 16 Go ne garantissent pas tous les profils.

Pour utiliser le kit d'accompagnement : décompressez-le, lancez **INSTALL.cmd**, choisissez un dossier vide et attendez la vérification des fichiers. Indiquez ensuite ce dossier dans **Model > BeeLlama folder** et réglez le contexte sur 64K. Suivez sa notice pour les prérequis et les contrôles détaillés.

Référence : BeeLlama v0.4.9 et ses fichiers.

## OpenAI, Anthropic et API compatible

Renseignez la clé et les paramètres demandés pour le fournisseur choisi. Avec une API compatible, utilisez l'adresse et l'identifiant de modèle fournis par votre service. Vérifiez ses limites de contexte et la prise en charge des outils.

Les tarifs, quotas et modèles accessibles relèvent du fournisseur. Une erreur d'authentification ou de quota ne se corrige pas en augmentant le contexte.

# Les outils de l'agent

ShaetherLm propose **17 outils intégrés**, auxquels s'ajoute **n8n_run_workflow** lorsque n8n et un workflow autorisé sont configurés. Les skills apportent des méthodes, sans ajouter automatiquement de nouveaux outils.

| Usage | Outils |
|---|---|
| Fichiers | list_files, read_file, write_file, search_in_files |
| Code et exécution | apply_patch, run_command, python_exec |
| Documents | read_pdf, read_docx, read_excel, create_pdf |
| Web | web_search, web_fetch |
| Images | see_image |
| Calcul et date | calculate, get_datetime |
| Mémoire durable | long_term_memory |
| Automatisation facultative | n8n_run_workflow |

## Lire le nécessaire

Les listes, recherches et lectures peuvent être ciblées et paginées. L'agent n'a pas besoin d'inventorier des milliers de fichiers pour retrouver un document dont vous connaissez le dossier.

## Vérifier les créations

Une commande peut exécuter des tests ou un outil installé. **run_command** n'impose pas de durée maximale fixe ; **STOP** reste disponible et la sortie est limitée. **python_exec** conserve ses propres limites.

## Explorer le Web

La recherche fournit des pistes ; **web_fetch** récupère le contenu accessible. La récupération de transcriptions vidéo dépend de leur disponibilité et du site. Un outil de transcription externe reste un complément distinct.

L'accès à un outil ne garantit pas son bon usage par chaque modèle. Pour un travail sensible, exigez une vérification du résultat.

# Choisir ce qui reste local

| Fonction | Où les données sont traitées |
|---|---|
| Modèle local Ollama / BeeLlama | Sur votre machine pour l'inférence locale. |
| API ou modèle cloud | Chez le fournisseur, pour les informations envoyées au modèle. |
| Recherche et récupération Web | Auprès des services et sites interrogés. |
| Vision et transcription Groq | Chez Groq pour les données nécessaires à ces fonctions. |
| Listen | Chez Microsoft pour le texte à transformer en voix. |
| Mémoire longue durée | Stockée dans le Workspace ; extraction avec le modèle sélectionné. |
| n8n | Selon votre serveur et les services appelés par ses workflows. |

## Les protections et leur portée

Les outils contrôlent les chemins, les commandes et les autorisations. Le Workspace constitue le périmètre prévu. Cependant, un script ou programme lancé dispose des droits de votre compte Windows : l'application n'est pas une isolation complète du système.

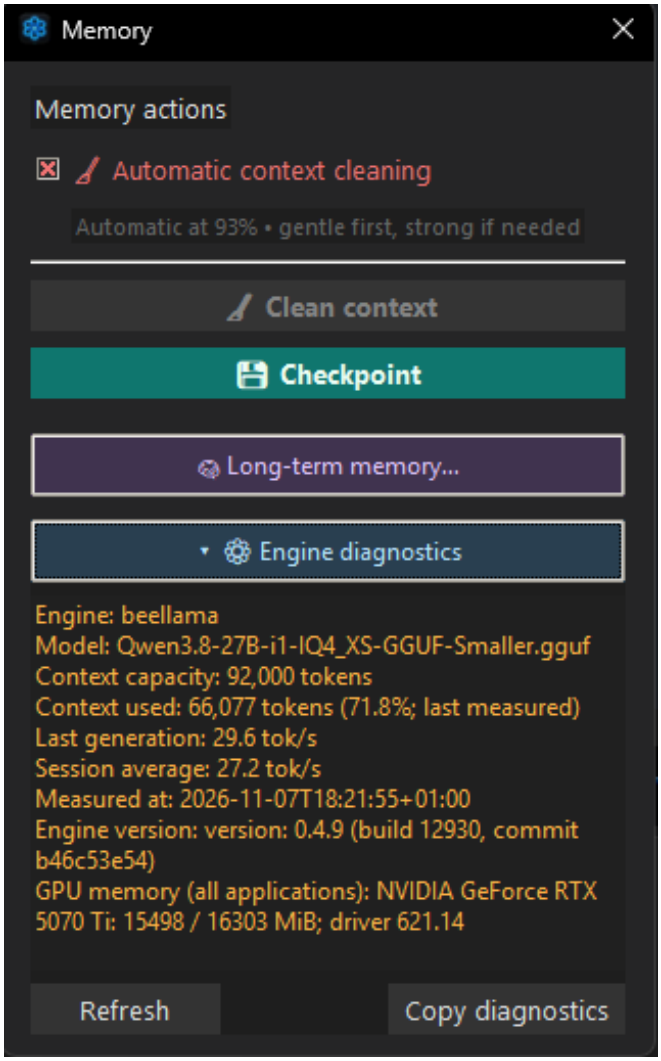
Le mode autonome désactive certaines confirmations, pas les contrôles de refus. Une commande mal formée peut être renvoyée à l'agent pour correction plutôt que vous demander une autorisation inutile.

Choisissez vos skills et programmes externes avec soin. Gardez les clés API privées et vérifiez les captures ou journaux avant de les partager.

## Conserver une copie utile

Sauvegardez vos fichiers, vos checkpoints et votre configuration avant un changement important. **Forget** retire un souvenir du rappel mais n'efface pas automatiquement ses documents sources ni les sauvegardes.

# Lire les chiffres utiles




*Le panneau Memory et les diagnostics du moteur, disponibles à la demande.*

Le contexte affiché peut être estimé avant qu'une réponse fournisse la mesure du moteur. Messages visibles, messages actifs et archives ne représentent pas la même quantité d'informations envoyées au modèle.

La vitesse en tokens par seconde décrit la génération mesurée, pas toute la durée d'une tâche : lecture du contexte, outils, réseau et attente peuvent aussi compter. La mémoire GPU affichée peut inclure d'autres applications.

Ces diagnostics servent à comparer vos essais avec le même modèle et les mêmes réglages, sans encombrer en permanence la conversation.

# Les bons réflexes

| Symptôme | Première vérification |
|---|---|
| Le moteur ne démarre pas | Dossier, modèle, clé ou adresse dans Settings. Évitez deux serveurs sur le même port. |
| Une relance très rapide échoue | Attendez la fermeture effective du moteur avant de relancer. |
| Le modèle devient lent | Réduisez le contexte et regardez la charge mémoire ; vérifiez les autres applications. |
| Limite de réponse sans texte final | La reprise automatique est bornée. Si nécessaire, augmentez Max response tokens ou découpez la tâche. |
| Une commande est refusée | Faites relire le motif à l'agent et corriger la demande ; ne contournez pas le refus par un autre outil. |
| Des souvenirs demandent une révision | Ouvrez Long-term memory > Review next source. Les souvenirs déjà valides restent conservés. |
| Un skill n'est pas utilisé | Vérifiez son activation, son Workspace et ses prérequis ; nommez-le dans la demande. |
| Listen s'arrête | Vérifiez Internet et le service ; réessayez plus tard ou avec une autre voix. |
| Un document paraît vide | Vérifiez son format : un PDF scanné peut nécessiter une analyse d'image. |

## Signaler un problème utilement

Indiquez l'action réalisée, le moteur, le modèle et le message d'erreur exact. Ajoutez une capture si elle aide, sans clé API ni donnée personnelle inutile.

Si l'agent perd le fil, donnez le chemin du dernier fichier ou checkpoint vérifiable. Une source précise est souvent plus utile qu'un nouvel audit complet.

# Votre prochaine tâche commence ici

Vous n'avez pas besoin d'utiliser toutes les fonctions. Commencez par un document, une idée ou une tâche réelle. Ajoutez ensuite la voix, un souvenir durable, un skill ou une automatisation lorsque cela vous rend service.

> « Aide-moi à organiser ce dossier. Commence par les documents de premier niveau et propose un classement avant toute modification. »

> « Prépare une page HTML pour présenter mon projet. Fais une première version que je pourrai ouvrir et commenter. »

> « Retrouve notre dernière décision sur ce projet dans la mémoire, puis vérifie le fichier correspondant avant de poursuivre. »

## Quelques repères

| Mot | Sens |
|---|---|
| Workspace | Votre dossier de travail pour les fichiers et créations. |
| Modèle | L'IA qui produit les réponses et choisit les outils. |
| Moteur | Le logiciel ou service qui fait tourner le modèle. |
| Contexte | Les informations prises en compte pour la réponse. |
| Checkpoint | Un état de transmission pour reprendre un travail. |
| Skill | Une méthode réutilisable que l'agent peut consulter. |

## Suivre et soutenir le projet

Présentation du projet · Versions et téléchargements · Soutenir sur Ko-fi

**Contact : shaetherlm@gmail.com**

ShaetherLm V1.0 · Freeware sous licence propriétaire · © Sébast242.

Guide français du 7 novembre 2026. Les captures montrent des sessions réelles : chemins, noms, modèles et compteurs sont des exemples. Les services externes et leurs conditions peuvent évoluer.