SHAETHERLM V1

GUIDE D'UTILISATION · ÉDITION FRANÇAISE



Votre assistant. Votre espace.

Conversez. Explorez. Créez.

Des premiers réglages aux longues sessions de travail, un guide pour prendre vos repères et garder le fil.

Local & API · Documents · Agent · Mood Pulse

21 septembre 2026

© Seb242

Votre guide, à votre rythme

Commencez par les premières pages, puis retrouvez directement la fonction qui vous intéresse. Les entrées ci-dessous sont cliquables.

Votre première conversation	03
Se repérer dans Settings	04
Choisir et préparer son moteur	05
Connecter un fournisseur API	06
Votre espace de conversation	07
Les commandes utiles	08
Le Workspace et les pièces jointes	09
PDF, Word et Excel en pratique	10
Web, images et vidéos	11
Confier une tâche au mode Agent	12
Modifier du code avec précision	13
Choisir l'autonomie du terminal	14
La voix et le suivi du texte	15
Une expression qui accompagne le chat	16
Comprendre le contexte	17
Nettoyer sans repartir de zéro	18
Laisser le nettoyage accompagner l'Agent	19
Sauvegarder et retrouver le fil	20
Changer de Workspace sans mélanger les sessions	21
Savoir ce qui quitte l'ordinateur	22
Relier l'assistant à n8n	23
Connexion et démarrage : les bons contrôles	24
Outils, documents et mémoire	25
Reconnaître un démarrage réussi	26
Quelques demandes pour commencer	27

Les libellés en gras reprennent les commandes de l’application. Les services en ligne et les fonctions avancées restent facultatifs.



Votre première conversation

ShaetherLM réunit une conversation avec une IA, des outils pour travailler sur vos fichiers et une expression visuelle facultative : **Mood Pulse**. Aether est le nom proposé pour l'assistant ; vous pouvez le changer. L'interface est en anglais, ce guide vous accompagne en français.

1. Choisissez où faire tourner l'IA

Utilisez **Ollama** ou **BeeLlama** pour un moteur local, ou un fournisseur API si vous disposez de ses accès. Ollama propose aussi des modèles cloud. Les modèles locaux et les accès payants ne sont pas inclus dans l'EXE.

2. Ouvrez les réglages

Lancez l'application. Dans **Settings > Connection**, choisissez **AI backend**. Dans **Assistant**, renseignez **AI nickname** et **Preferred language**. La langue choisie concerne la conversation, pas les libellés de l'interface.

3. Choisissez votre Workspace

Dans **Assistant**, utilisez **Create Workspace** ou **Choose**. Préférez un dossier dédié, par exemple dans vos Documents. C'est là que l'assistant travaillera sur vos fichiers. Aucun disque D: ni dossier personnel du créateur n'est requis.

4. Préparez le modèle et enregistrez

Dans **Model**, sélectionnez le modèle et ses réglages. Pour une API, renseignez d'abord la clé dans **Connection**. Cliquez sur **Save & Launch** au premier lancement, ou **Save & Apply** ensuite. Attendez le message de disponibilité.

5. Faites un premier essai

Saisissez votre demande, puis cliquez sur **SEND** ou appuyez sur **Ctrl + Entrée**.

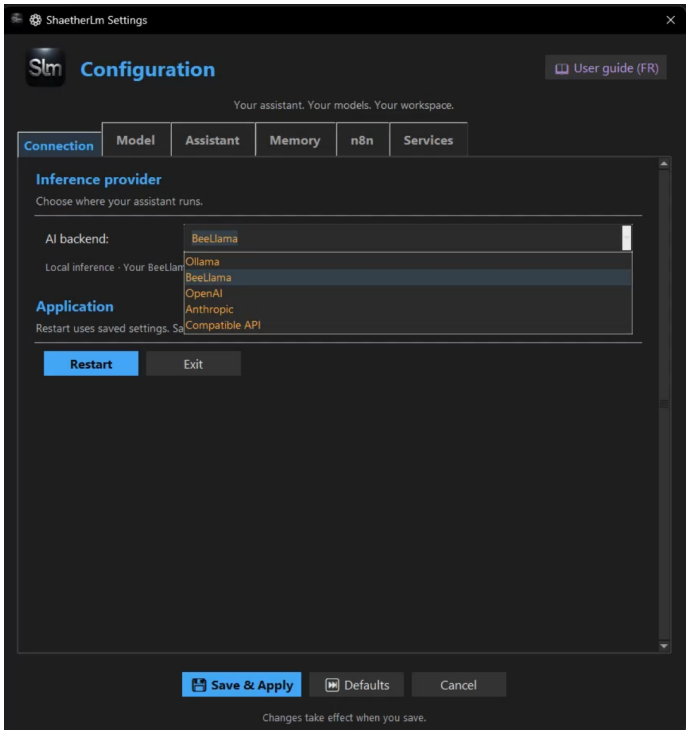
> « Bonjour Aether. Explique-moi ce que tu peux faire, puis indique la date et l'heure actuelles. »

Essayez ensuite un petit document. Agent, le micro, n8n et Mood Pulse sont facultatifs. Les chapitres suivants détaillent les moteurs et leurs réglages.

À prévoir : un emplacement où l'application peut enregistrer sa configuration et un moteur opérationnel. L'EXE n'exige pas Python pour ouvrir l'interface ; l'exécution de scripts Python nécessite un interpréteur disponible. Annuler la configuration initiale quitte l'application.

Se repérer dans Settings

User guide (FR) ouvre ce PDF. Les six onglets séparent les connexions, le modèle et les fonctions de l'assistant.



Connection : sélection du fournisseur et commandes Restart / Exit. Les valeurs de cette session sont des exemples.

Onglet	Ce que vous y réglez
Connection	Fournisseur, clé API éventuelle, Restart et Exit.
Model	Modèle, capacité de contexte et génération.
Assistant	Nom, langue, Workspace et autorisations Agent.
Memory	Nettoyage automatique et récupération de continuité.
n8n	Workflows, événements et résultats différés.
Services	Web, Groq, voix et son de fin.

Save & Launch / Save & Apply enregistre et applique. **Cancel** ferme sans appliquer ; **Defaults** remet les valeurs par défaut.

Restart relance avec les réglages enregistrés : appliquez vos changements auparavant. **Exit** ferme l'application. Ouvrir Settings demande l'arrêt du travail en cours ; sa fin peut prendre un instant.

Choisir et préparer son moteur

Le **moteur** fait tourner le **modèle**, qui produit les réponses et choisit les outils. Les capacités, la vitesse et la qualité des appels d'outils dépendent aussi du modèle.

Ollama : local ou cloud

Installez Ollama pour Windows et laissez son service fonctionner en arrière-plan. Pour un modèle local, téléchargez-le dans Ollama ; privilégiez un modèle compatible avec les appels d'outils. Dans un terminal, **ollama pull NOM_DU_MODELE** permet de le récupérer en remplaçant NOM_DU_MODELE par son nom exact. Dans **Settings > Connection**, choisissez **Ollama**, puis utilisez **Model > Refresh Ollama** et sélectionnez le modèle.

Les modèles distants apparaissent dans la même liste, avec une terminaison **:cloud** ou **-cloud**. Pour les utiliser, connectez Ollama à votre compte avec la commande **ollama signin**, puis actualisez la liste. Internet, les accès et les quotas du compte s'appliquent. Voir la documentation Ollama Cloud.

> **Local ou distant ?** Avec un modèle cloud, le contexte et les résultats d'outils qui lui sont envoyés sont traités à distance. Les outils de ShaetherLM s'exécutent toujours sur votre ordinateur.

BeeLlama : une installation locale préparée

Choisissez **BeeLlama** dans **Connection**, puis indiquez **BeeLlama folder** dans **Model**. Ce dossier doit contenir le serveur et ses bibliothèques, un modèle GGUF compatible et son modèle de conversation :

```
Dossier BeeLlama/
  beellama/llama-server.exe   (+ les DLL du serveur)
  models/                     (le modèle GGUF)
  chat_template.jinja
```

Pour préparer cette installation, récupérez le GGUF de référence dans models et un template Qwen adapté, enregistré en texte sous **chat_template.jinja**. Gardez les DLL fournies avec la même version du serveur.

L'application est configurée pour une installation Qwen3.8-27B BeeLlama. Conservez un ensemble serveur, GGUF et template cohérent ; déposer n'importe quel GGUF ne garantit pas sa compatibilité. Le projet BeeLlama fournit les ressources du moteur. L'application lance son serveur local au besoin.

Trois réglages à ne pas confondre

Ollama context / BeeLlama context détermine la capacité de travail de la conversation. Une valeur élevée consomme davantage de mémoire et doit être supportée par le modèle et le matériel.

Max response tokens limite une génération, et non tout l'historique. **Thinking mode** active la réflexion lorsque le moteur et le modèle la prennent en charge. **BeeLlama MTP speculative decoding** est une option du moteur ; commencez avec une configuration qui fonctionne, puis comparez son effet sur votre machine.

Connecter un fournisseur API

Une API permet d'utiliser un modèle distant tout en gardant les outils et le Workspace sur votre ordinateur. Il faut une clé et un accès API actif chez le fournisseur choisi.

Choix dans Connection	Connexion utilisée
OpenAI	API Responses, adresse préconfigurée.
Anthropic	API native Claude, adresse préconfigurée.
Compatible API	Serveur compatible Chat Completions ; renseigner sa Base URL.

Un parcours en cinq étapes

1. Dans **Settings > Connection**, sélectionnez le fournisseur et renseignez **API key**. Chez Anthropic, **Workspace ID** est facultatif et ne sert qu'aux clés couvrant plusieurs espaces Anthropic.

2. Cliquez sur **Test & refresh models**, ou sur **Refresh** dans **Model**. L'actualisation liste les modèles accessibles sans générer de réponse.

3. Dans **Model**, choisissez un modèle de conversation avec appels d'outils. Vous pouvez aussi saisir son identifiant exact. La présence au catalogue ne garantit pas toutes les fonctions.

4. Réglez **Context budget** et **Max output tokens** dans les limites du modèle. Gardez **Reasoning / Effort** sur **default** si vous ne connaissez pas ses valeurs acceptées.

5. Enregistrez, essayez une demande courte, puis un outil simple, comme la date et l'heure.

Le budget de contexte est une limite de l'application, pas une extension de la capacité du serveur. Le plafond de sortie peut inclure les tokens de réflexion. Les profils des fournisseurs sont conservés séparément.

> **Facturation distincte** - L'abonnement ChatGPT et les crédits Codex ne paient pas les appels API de ShaetherLM. Les réponses, les étapes Agent et le nettoyage du contexte peuvent être facturés par le fournisseur.

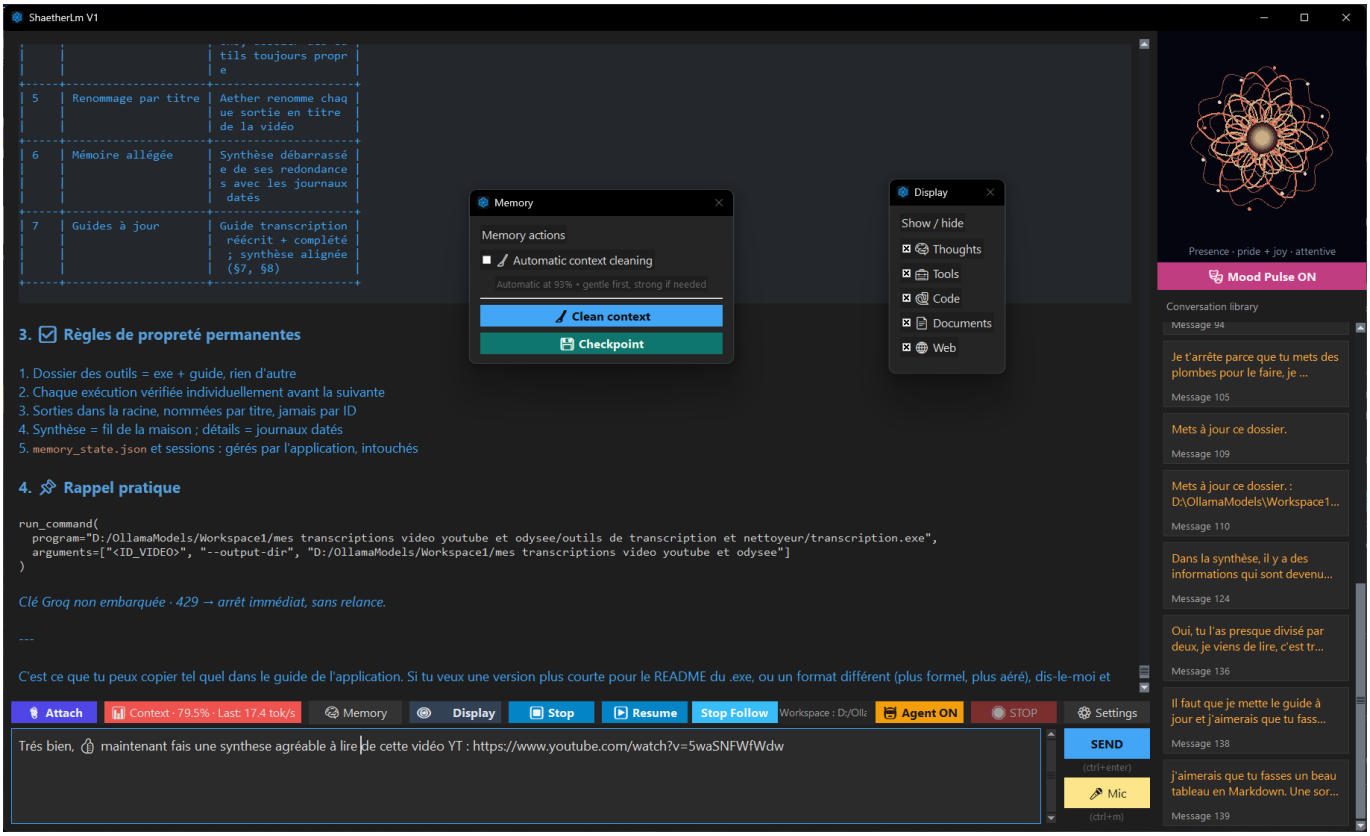
Garder la maîtrise des accès

Les clés saisies dans cette configuration sont protégées pour votre compte Windows. Un champ vide conserve la clé ; **Remove saved key** la retire. Sur un autre PC ou compte Windows, ressaisissez-la. Changer l'adresse d'une API compatible exige également de ressaisir sa clé.

STOP empêche la poursuite du travail dans l'application. Une requête déjà reçue peut néanmoins se terminer et rester facturée côté fournisseur. Un échec d'actualisation conserve la liste précédente ; un refus de quota doit être résolu auprès du fournisseur.

Votre espace de conversation

Le chat et la saisie occupent la zone principale. À droite, Mood Pulse et la bibliothèque restent accessibles dans la même fenêtre.



La fenêtre principale avec Memory et Display ouverts, la lecture vocale et la bibliothèque. Les chemins et contenus illustrent une session personnelle.

Écrire, lire et retrouver

En bas, rédigez votre demande, joignez vos documents et envoyez. Les commandes restent accessibles lorsque la taille de la fenêtre change ; le chat absorbe l'espace disponible.

Au centre, suivez les réponses et les outils. **Display** permet de masquer des catégories pour rendre la lecture plus légère.

À droite, les capsules de **Conversation library** reprennent le début de vos messages. Cliquez pour rejoindre le passage et le surligner brièvement ; survolez pour lire le texte complet. Le numéro de message, ou les dates et tags disponibles, servent de repères.

> **Un raccourci dans le chat** - Cette bibliothèque indexe la conversation affichée, pas toutes les sessions sur disque. Naviguer n'ajoute rien au contexte et ne déclenche pas l'IA. Pour reprendre à cet endroit, utilisez le clic droit du message.

La position, les dimensions et l'état maximisé sont mémorisés à la fermeture normale. Au lancement, la fenêtre est ajustée à l'espace disponible si l'écran a changé. Un second lancement remet l'instance existante au premier plan.

Les commandes utiles

Commande	Utilisation
Attach	Joindre un fichier pris en charge. Le glisser-déposer dans le chat sert au même usage.
Context / Memory	Afficher l'occupation du contexte, puis les actions de mémoire.
Display	Montrer ou masquer Thoughts, Tools, Code, Documents et Web.
Listen	Écouter la dernière réponse. Les commandes vocales évoluent pendant la lecture.
Agent	Activer le travail en plusieurs étapes. L'état actif est indiqué sur le bouton.
Mood Pulse	Activer l'expression visuelle de l'assistant.
STOP	Demander l'interruption du travail de l'IA. Ce n'est pas le Stop de la lecture vocale.
Settings	Ouvrir les réglages et le guide.
SEND / Ctrl + Entrée	Envoyer le texte de la zone de saisie.
Mic / Ctrl + M	Démarrer la dictée vocale.

Ajuster l'affichage

Thoughts concerne la réflexion visible ; le masquer ne désactive pas **Thinking mode**. De même, masquer les outils ou les documents ne les retire pas du contexte : c'est un choix de présentation.

Les tableaux sont affichés en texte copiable. Les tableaux très larges peuvent être répartis en plusieurs groupes de colonnes. Les blocs de code restent lisibles dans la conversation.

Corriger une demande

Un clic droit sur votre message donne accès à **Edit this message** et **Delete from here**. L'édition recharge le texte dans la saisie et retire la suite de la conversation ; vous pouvez le corriger puis le renvoyer.

> **Revenir dans le chat n'annule pas une action déjà faite.** Un fichier écrit ou un workflow déclenché reste inchangé tant que vous ne demandez pas une nouvelle action.

Dans la zone de saisie, le clic droit donne accès à la palette d'émojis. Les contrôles peuvent être indisponibles pendant une opération qui doit se terminer.

Le Workspace et les pièces jointes

Le **Workspace** est le dossier de travail des outils de fichiers. Vous y retrouvez vos documents, les productions de l'assistant et les archives. Son chemin apparaît dans l'interface.

Joindre un document

Cliquez sur **Attach**, ou déposez le fichier dans le chat, puis écrivez ce que vous voulez en faire. Un document joint est copié dans le Workspace ; s'il s'y trouve déjà à l'emplacement attendu, il est réutilisé. Un homonyme distinct reçoit un autre nom au lieu d'écraser le premier.

Type	Prise en charge
Texte et code	TXT, MD, PY, JSON, CSV, HTML, ainsi que les formats texte Godot et C# acceptés par l'application.
PDF	Extraction du texte disponible dans le document.
Word	DOCX : lecture du corps du document et de ses tableaux.
Excel	XLSX : lecture de feuilles, plages de cellules, valeurs ou formules.
Images	Analyse via le service de vision configuré dans Services.

Les fichiers **DOC et XLS**, PowerPoint et les autres extensions non prises en charge doivent être convertis avant d'être joints. Renommer une extension ne convertit pas le fichier.

Joindre n'est pas forcément tout lire

Un petit fichier texte est directement intégré. Au-delà de **8 000 caractères**, l'application fournit au modèle une référence pour le lire à la demande. PDF, Word et Excel sont également lus par leurs outils, selon la tâche.

> **Exemple** - « Lis ce document et relève les trois décisions, les échéances et les points encore ouverts. Si tu n'as pas tout parcouru, précise ce qui reste à lire. »

Les gros résultats d'outils peuvent être présentés sous forme d'aperçu, avec leur contenu reçu conservé dans **.tool_results**. L'assistant peut en lire la suite. Cette économie de contexte ne dispense pas de lui demander une lecture complète lorsqu'elle est nécessaire.

PDF, Word et Excel en pratique

PDF : rechercher et résumer

Demandez une synthèse, une recherche précise ou une comparaison entre documents. Le texte est lu par morceaux ; une lecture ne correspond pas nécessairement à une page du PDF original.

> « Dans ce PDF, retrouve les conditions de résiliation, puis résume-les en citant les passages concernés. »

Un PDF scanné peut ne contenir aucune couche de texte exploitable. Cette lecture ne réalise pas d'OCR automatique. Pour ces fichiers, utilisez une version avec texte reconnu ou une image lisible avec le service de vision.

Word : le contenu avant la présentation

La lecture **DOCX** extrait le texte du corps et les tableaux. Elle ne reproduit pas la mise en page, les en-têtes et pieds de page, les zones de texte flottantes ou le texte des images.

> « Lis ce DOCX, relève les incohérences entre les paragraphes et les tableaux, puis propose une version corrigée dans un nouveau fichier Markdown. »

L'outil Word sert à lire le document. Il ne constitue pas un éditeur Word complet. Certains documents chiffrés ou particuliers peuvent être illisibles.

Excel : poser une question ciblée

Indiquez si possible la feuille et la plage utiles. Sans autre indication, l'outil utilise une plage limitée, **A1:J30** ; il peut lire jusqu'à **2 000 cellules par appel**.

> « Dans ventes.xlsx, examine la feuille Juin, cellules A1:H120. Calcule les totaux par catégorie et signale les valeurs manquantes. »

L'assistant peut demander les valeurs enregistrées ou les formules. L'outil ne modifie pas le classeur et ne recalcule pas ses formules. Une valeur **null** peut être une cellule vide ou une formule dont le résultat n'a pas été enregistré. Dans ce dernier cas, ouvrez, recalculez et enregistrez le fichier dans votre tableur.

Les graphiques, couleurs et formats de cellules ne sont pas interprétés comme une mise en page. Demandez une autre plage pour poursuivre l'analyse d'un grand classeur.

Produire un résultat

L'assistant peut enregistrer un texte, du Markdown, du code ou créer un PDF avec ses outils. Précisez le nom du fichier souhaité et demandez qu'il confirme le chemin après l'écriture. Relisez le résultat avant de l'utiliser ou de le partager.

Web, images et vidéos

Rechercher puis consulter

L'assistant peut rechercher des pages et en extraire du contenu. Dans **Settings > Services**, choisissez le fournisseur de recherche : **duckduckgo**, **brave** ou **ollama**. Brave et la recherche Ollama nécessitent leur clé configurée ; DuckDuckGo n'en demande pas.

> « Cherche les informations récentes sur ce sujet, ouvre les sources utiles et sépare les faits vérifiés de tes déductions. »

Une page protégée, payante ou très dynamique peut ne pas être accessible à l'outil. Demandez les sources et leur date lorsque l'actualité compte. Une recherche web n'est pas une garantie d'exhaustivité.

Poser une question sur une image

Joignez une image, ajoutez votre question et envoyez. L'analyse passe par **Groq** avec le **Vision model** configuré dans Services ; une clé Groq et Internet sont nécessaires.

> « Décris cette capture et explique le message d'erreur, sans inventer ce qui n'est pas visible. »

Les images en attente peuvent être retirées avant l'envoi. Une petite image ou un texte flou limite la précision de l'analyse. Joindre une image n'active pas automatiquement une vision locale dans le modèle de conversation.

Lire une vidéo YouTube

Donnez son URL et demandez une synthèse de ses sous-titres ou de sa transcription accessible. Le contenu textuel disponible peut être lu par morceaux.

> « Résume les arguments de cette vidéo à partir de sa transcription et indique ce que la transcription ne permet pas de vérifier. »

Si les sous-titres sont absents ou bloqués, l'outil intégré peut échouer. Il n'analyse pas pour autant les images ou l'audio de la vidéo. La transcription de l'audio nécessite un outil externe, **non fourni avec ShaetherLM**.

Retrouver la suite sans tout recommencer

Les lectures successives d'une même page web ou transcription peuvent réutiliser le contenu récemment récupéré. Les extractions de documents locaux sont également réutilisées tant que le fichier n'a pas changé. Ce cache est temporaire, reste en mémoire et ne demande aucun entretien.

Confier une tâche au mode Agent

Le mode Agent permet d'enchaîner des actions vers un résultat : rechercher, lire, comparer, calculer, écrire et vérifier. Le mode normal sait aussi utiliser des outils ; **Agent** encourage un travail plus autonome et prolongé.

Formuler une mission facile à vérifier

Précisez le résultat attendu, les fichiers concernés et les limites utiles. Une demande concrète donne au modèle un point d'arrivée.

> « Analyse les trois rapports joints. Crée synthese.md avec les points communs et les divergences. Vérifie que chaque conclusion s'appuie sur un rapport. Conserve les fichiers d'origine. »

L'Agent peut enchaîner les étapes nécessaires à la tâche, sans nombre maximal d'étapes prédéfini. Les **Step** affichés vous permettent de suivre sa progression ; ils ne mesurent pas la justesse du résultat. Vous pouvez interrompre le travail avec **STOP**.

Quand une génération arrive à sa limite

Si le moteur signale explicitement une limite de génération, l'Agent peut demander automatiquement la suite et assembler la réponse. Les outils déjà exécutés ne sont pas automatiquement rejoués pour cette reprise.

Une réponse terminée normalement n'entraîne pas de relance forcée. Si le moteur atteint sa limite sans fournir de texte exploitable, l'application peut vous inviter à augmenter **Max response tokens**.

Interrompre et reprendre

Le bouton **STOP** demande l'arrêt du travail. L'interruption d'un appel en cours dépend du moteur ou de l'outil. Elle n'annule pas les modifications déjà enregistrées. Après l'arrêt, indiquez ce qu'il faut reprendre, corriger ou laisser en place.

Écritures protégées, sauvegardes distinctes

L'outil d'écriture prépare le contenu dans un fichier temporaire avant de remplacer la destination. Cela évite de laisser une destination partiellement écrite lors d'un échec pendant la préparation. Le mode ajout est également protégé.

Cette protection n'est pas un historique de versions. Un remplacement réussi remplace bien l'ancien contenu. Pour un journal, demandez explicitement un **ajout à la suite**, et conservez des sauvegardes des fichiers importants.

L'outil **python_exec** peut exécuter des scripts avec les droits de votre compte Windows. Le Workspace n'est pas un confinement de ces scripts ; leurs écritures directes ne bénéficient pas automatiquement de la protection de l'outil de fichiers.

Modifier du code avec précision

L'Agent dispose de deux outils spécialisés, utiles pour Godot comme pour Python, le web ou d'autres projets. Les logiciels nécessaires aux tests et compilations doivent être installés séparément.

apply_patch : une modification ciblée

Au lieu de réécrire tout un fichier, l'assistant fournit le bloc à remplacer et son nouveau contenu. L'ancien bloc doit apparaître **exactement une fois** : sinon, l'outil refuse plutôt que de choisir un emplacement incertain.

L'outil conserve les fins de ligne et les encodages pris en charge, prépare un fichier temporaire, puis remplace la destination de façon atomique. Il renvoie le diff réel, c'est-à-dire les lignes modifiées.

Les fichiers binaires, les cibles hors Workspace, les fichiers de plus de 8 Mio et les modifications concurrentes détectées sont refusés. La copie temporaire est nettoyée automatiquement ; ce n'est pas une sauvegarde de versions.

run_command : vérifier avec les vrais outils

L'assistant peut lancer une recherche, consulter Git, exécuter des tests ou compiler, depuis un dossier du Workspace. Il reçoit le code de sortie et une sortie limitée pour ne pas saturer le contexte.

Le délai par défaut est de **60 secondes**, réglable jusqu'à **300 secondes**. STOP et l'expiration du délai arrêtent le groupe de processus lancé. Les règles d'autorisation sont expliquées à la page suivante.

Pour Godot, **res://** est reconnu comme une ressource locale du projet lorsqu'il peut être identifié. Cette exception n'autorise pas une ressource située hors Workspace.

> **Un cycle simple** - Lire et rechercher, appliquer un petit patch, lancer le test adapté, lire les erreurs, puis corriger. Un patch réussi prouve que le texte a été remplacé, pas que le programme fonctionne.

Choisir l'outil adapté

write_file sert à créer un fichier ou à remplacer volontairement tout son contenu. Pour un journal, demandez un ajout. **python_exec** sert aux calculs, simulations et scripts.

Les motifs de **list_files** et **search_in_files** portent sur le nom : les extensions PDF et GD (motifs *.pdf et *.gd), ou le motif * pour tous les noms. Un motif de chemin comme **dossier/*.gd** est refusé avec une explication. Une recherche récursive parcourt les sous-dossiers et renvoie les chemins relatifs ; une liste sans récursion inclut les dossiers de la racine.

Choisir l'autonomie du terminal

Dans **Settings > Assistant > Agent**, **Command approval** fixe le niveau d'approbation de run_command. Ce réglage est mémorisé dans la configuration.

Choix	Comportement
Always ask	Demander avant chaque commande admissible, sauf accord de session.
Automatically allow safe commands	Autoriser les commandes reconnues comme sûres ; demander pour les autres. C'est le choix par défaut.
Workspace autonomous mode	Autoriser aussi les modifications de projet reconnues ; demander pour les commandes non classées.

Répondre à une demande

Allow once autorise seulement cette exécution. **Always allow for this session** dispense des demandes suivantes pour les commandes ayant passé les contrôles, y compris celles non classées. **Refuse** empêche l'exécution.

L'accord de session n'est pas enregistré dans le JSON. Il expire au redémarrage ou lorsque les paramètres sont appliqués. Il ne lève jamais une interdiction de l'outil.

Ce qui reste contrôlé

Les chemins extérieurs explicites, les liens résolus hors Workspace, les commandes système ou administrateur et les interpréteurs de shell sont refusés. Les arguments URL peuvent aussi être refusés par le filtre des cibles réseau. Un refus ne doit pas être contourné avec un autre outil.

Les délais, la limite de sortie et STOP restent actifs dans tous les modes. Chaque demande, décision et résultat borné est enregistré dans **Workspace/.command_logs**, y compris les refus. Ce dossier est écarté des recherches récursives ordinaires.

> **Un terminal encadré, pas une sandbox** - Un programme, un test ou un script peut calculer ses propres chemins et accéder au réseau avec les droits Windows de votre compte. Ces contrôles ne constituent pas une isolation complète du processus.

Définir le périmètre de la mission

Par défaut, l'assistant doit rester dans le Workspace. Avant un accès extérieur non déjà autorisé, il doit expliquer le chemin et l'opération, demander votre accord et attendre. Une mission de programmation ne donne pas permission d'explorer les disques.

N'insérez pas de secrets dans les arguments : ils peuvent apparaître dans les journaux. Gardez des sauvegardes ; une autorisation et un test réussi ne remplacent pas la relecture d'une modification importante.

La voix et le suivi du texte

Dicter une demande

Cliquez sur **Mic** ou utilisez **Ctrl + M**, puis terminez l'enregistrement avec la commande proposée. La transcription est insérée dans la zone de saisie : relisez-la avant **SEND**. Le micro ne transforme pas la dictée en envoi automatique.

Cette fonction utilise Groq et son **STT model**, configurés dans **Settings > Services**. Vérifiez l'accès au micro dans Windows si l'enregistrement ne démarre pas.

Écouter la dernière réponse

Cliquez sur **Listen**. La synthèse vocale utilise **Edge TTS** et demande Internet. Choisissez **TTS voice** dans Services. Une courte préparation peut précéder le son.



Les commandes vocales pendant une session : Stop, Resume et Stop Follow. Leur libellé dépend de l'état de lecture et de suivi.

Commande vocale	Effet
Stop	Arrête uniquement la lecture vocale, y compris pendant une itération de l'agent.
Pause / Resume	Met la lecture en pause ou la reprend.
Follow	Active le suivi du passage lu dans le chat.
Stop Follow	Désactive uniquement ce suivi. La voix continue et Pause / Resume reste disponible.

Stop Follow apparaît temporairement à droite de Pause / Resume ; il est bleu et clignote lorsqu'il est activable. Après sa désactivation, **Follow** permet de retrouver le passage courant.

> **Deux arrêts différents** - Le Stop vocal coupe la voix. Le grand bouton **STOP** concerne le travail de l'IA. Utilisez celui qui correspond à ce que vous voulez interrompre.

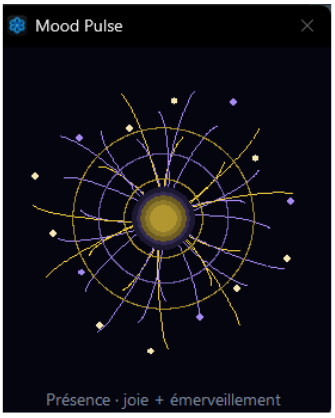
Être prévenu à la fin

Dans Services, **Completion sound** active un son de fin pour les réponses suffisamment longues à produire. Il accompagne la fin du travail, pas chaque étape intermédiaire.

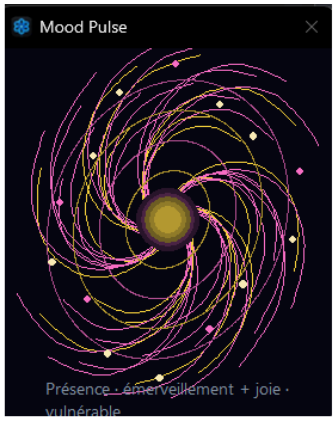
Les fichiers audio temporaires de la lecture sont normalement nettoyés automatiquement. Vous n'avez pas de dossier de lecture à vider à chaque utilisation.

Une expression qui accompagne le chat

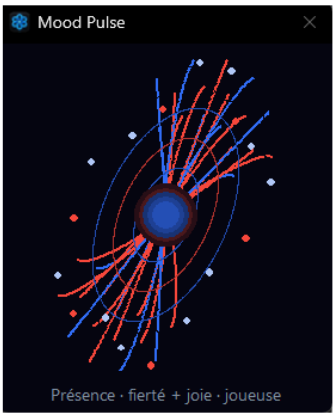
Mood Pulse occupe le haut de la colonne droite. L'assistant peut en faire évoluer la forme, les couleurs et le rythme. Le bouton **Mood Pulse ON / OFF**, sous le mandala, sert d'interrupteur : OFF fige le dernier motif et arrête l'animation.



Joie et émerveillement



Émerveillement, joie, vulnérabilité



Fierté, joie, jeu



Pendant la réflexion

Quatre exemples de formes et de couleurs du mandala. Les légendes décrivent l'ambiance de chaque illustration.

L'expression est choisie par le modèle et transmise avec sa réponse. Elle n'exige pas de fichier JSON externe ni d'appel séparé pour piloter le mandala. Vous pouvez lui proposer une ambiance, mais il n'est pas nécessaire de le diriger à chaque échange.

Pendant le travail, les étapes successives renforcent progressivement la pulsation et la déformation. L'intensité est plafonnée ; à la fin, le motif revient progressivement vers l'expression choisie.

L'information d'activation revient à chaque lancement, puis ne se répète plus pendant la session une fois acceptée. Les états sont en anglais, même dans une conversation française. Les métadonnées reconnues sont retirées du texte de la réponse.

Mood Pulse reste facultatif. Il représente une expression générée par le modèle, et non une mesure scientifique de son état interne ou la preuve d'une émotion ressentie. Les captures montrent des instants : le rendu réel est animé.

Comprendre le contexte

Le contexte contient ce que le modèle prend en compte pour sa prochaine réponse : messages, instructions, résultats d'outils et éventuelle mémoire de continuité. Il a une capacité limitée.



Le bouton Context indique l'occupation du contexte et la dernière vitesse de génération mesurée.

Le bouton **Context** affiche automatiquement le pourcentage occupé et **Last**, la dernière vitesse mesurée en tokens par seconde. Il se met à jour après les générations, les nettoyages et les restaurations ; il n'est pas nécessaire de cliquer pour rafraîchir sa couleur.

Couleur	Occupation du contexte
Vert	Moins de 50 %.
Jaune	De 50 % à moins de 65 %.
Orange	De 65 % à moins de 75 %.
Rouge	75 % ou plus ; ce n'est pas encore le seuil de nettoyage automatique.

Lire le bilan détaillé

Cliquez sur **Context** pour voir les compteurs. **Actual tokens** vient du moteur pour le dernier échange envoyé. **Estimated tokens**, ou **~** sur le bouton, signale une estimation, notamment après un nettoyage.

Active messages compte les messages envoyés au modèle ; **visible messages** ceux encore affichés. Les messages **archived** ont quitté le contexte actif. **Continuity memory** indique si un résumé de continuité est utilisé.

Last n'est pas une mesure instantanée, ni la durée totale des outils. La vitesse apparaît lorsqu'une mesure est disponible pour le moteur courant. Un token est une unité de texte, pas exactement un mot.

Pourquoi le compteur peut varier

Les lectures ciblées et les aperçus de gros résultats évitent de répéter inutilement du contenu. Ils ralentissent sa croissance sans rendre la fenêtre illimitée.

> **Masquer n'est pas compresser** - Display change la présentation. Pour libérer du contexte, utilisez Clean context ou activez le nettoyage automatique.

Nettoyer sans repartir de zéro

Ouvrez **Context**, puis **Memory > Clean context**. Le nettoyage conserve les échanges récents et remplace les plus anciens par une mémoire de continuité. Les originaux sont archivés en **Markdown et JSON** dans le Workspace.

Mode	Ce qui reste intact	Quand le choisir
Gentle	Les 4 derniers échanges complets.	Garder le détail récent d'une discussion ou d'un travail en cours.
Strong	Le dernier échange complet.	Libérer davantage de place après de longues lectures, recherches ou transcriptions.

Un échange peut contenir plusieurs messages et appels d'outils. « Garder le dernier échange » ne veut donc pas dire « garder un seul message ».

> **Objectif : 40 % de contexte occupé ou moins après nettoyage.** Il s'agit du niveau restant, pas d'une réduction de 40 %. Ce résultat dépend de la taille des échanges préservés et de la mémoire nécessaire.

Le résumé privilégie les décisions actuelles, contraintes, références utiles, tâches ouvertes et difficultés non résolues. Il peut condenser fortement des données devenues secondaires ; il ne conserve pas chaque phrase de l'historique.

Pendant et après le nettoyage

La préparation de la mémoire prend du temps, surtout avec un historique chargé. Attendez le message de résultat. Le bilan indique l'occupation avant et après, la place libérée estimée et l'emplacement de l'archive.

La conversation complète reste visible pendant la session, mais seuls les éléments actifs sont envoyés au modèle. Le prochain échange permet de remplacer l'estimation par le comptage fourni par le moteur.

Si la mémoire produite est tronquée, invalide ou n'apporte pas de gain estimé, **le contexte existant est conservé**. L'application ne remplace pas la conversation par un résumé inutilisable.

Choisir le bon moment

Le nettoyage manuel devient disponible lorsqu'il existe assez d'échanges complets à archiver. Pour les longues tâches, activez le mode automatique décrit à la page suivante : l'application choisit alors le moment et l'intensité.

Laisser le nettoyage accompagner l'Agent

Dans **Settings > Memory**, cochez **Automatic context cleaning**. Vous pouvez aussi l'activer dans la fenêtre **Memory**. Aucun pourcentage ni niveau Strong n'est à régler pour ce mode.

À partir de 93 %, au prochain point sûr

L'application vérifie le contexte avant de solliciter à nouveau le modèle. Pendant une suite d'actions, elle attend d'avoir enregistré tous les résultats de la série d'outils en cours avant de compresser.

Elle privilégie **Gentle**. Elle passe à **Strong** si les échanges conservés empêchent un allègement suffisant ou si la mémoire douce ne peut pas être produite correctement. Le choix Gentle / Strong reste disponible pour un nettoyage manuel.

Continuer le travail après la compression

Après réussite, une tâche encore en cours reprend automatiquement avec l'indication **Memory compression is complete** et une consigne de poursuivre sans répéter les actions terminées. Une réponse déjà achevée ne déclenche pas une nouvelle tâche spontanée.

Pour une très longue tâche unique, les anciennes étapes d'outils peuvent aussi être archivées. La dernière série complète reste active, les appels restent associés à leurs résultats et la demande utilisateur est préservée dans la mémoire. Le chat visible et les archives complètes sont conservés.

> **93 % est un déclencheur, pas une garantie de place** - Un gros résultat d'outil peut faire dépasser le seuil entre deux contrôles. La quantité de données indispensables et les limites du moteur peuvent encore empêcher le nettoyage.

Si le moteur refuse un contexte trop long

Une erreur **HTTP 400 explicitement liée à la longueur du contexte** peut déclencher une compression, puis **une seule tentative de reprise par tour utilisateur**. Une autre erreur 400 n'est pas traitée comme un dépassement de contexte.

Si cette reprise échoue, l'application s'arrête au lieu de relancer en boucle. **STOP reste prioritaire**. Une mémoire invalide ou sans gain ne remplace pas l'historique actif ; le message d'échec vous indique ce qui s'est passé.

Le nettoyage demande du temps de calcul et peut être facturé avec une API. Surveillez les premiers essais avec votre modèle pour vérifier que le résultat correspond à votre usage.

Sauvegarder et retrouver le fil

Trois mécanismes répondent à trois besoins différents.

Clean context : continuer la session actuelle

Le nettoyage allège le contexte et garde le chat en cours. Ses archives se trouvent dans **Workspace/Checkpoints**, dans un sous-dossier de session. Elles permettent de retrouver le contenu ancien si un détail a été trop résumé.

Checkpoint : préparer un nouveau départ

Dans **Memory**, choisissez **Checkpoint**. L'assistant prépare une synthèse de transmission, puis une fenêtre vous propose de l'enregistrer dans le Workspace, en texte ou Markdown.

Après un enregistrement réussi, un nouveau chat est créé. Annuler l'enregistrement ne déclenche pas ce nouveau chat. Le checkpoint sert de document de reprise ; ce n'est pas une sauvegarde intégrale de tous les fichiers manipulés.

> **Pour reprendre** - « Lis le checkpoint que j'ai enregistré, résume où nous en étions et reprends la tâche encore ouverte. »

Recovery : reprendre une continuité enregistrée

Dans **Settings > Memory > Recovery**, trois choix sont proposés :

• **Ask** : demander avant de reprendre la mémoire disponible.

• **Automatic** : reprendre automatiquement lorsqu'un état admissible existe.

• **Never** : ne pas utiliser cette reprise au démarrage.

Cette récupération s'applique aux sessions marquées pour continuité par les fonctions de nettoyage automatique ou n8n. **Un nettoyage manuel seul, avec ces fonctions désactivées, ne garantit pas une reprise automatique au prochain lancement.** Pour un passage de relais explicite, enregistrez un checkpoint.

Que faut-il conserver ?

Élément	Rôle
Workspace / Checkpoints	Archives et états de continuité utilisés par l'application.
Vos checkpoints enregistrés	Documents de transmission que vous pouvez faire relire.
Workspace / .tool_results	Contenus de gros résultats encore référencés par des échanges ou archives.
IAconfig.json, près de l'application	Réglages, chemins et éventuelles clés de services.

Sauvegardez le Workspace et les documents importants. Ne supprimez pas leurs archives ou résultats associés tant que vous voulez pouvoir retrouver les détails d'une ancienne session.

Changer de Workspace sans mélanger les sessions

Un Workspace regroupe un travail : fichiers, archives et éventuelle mémoire de continuité. Pour passer à un autre projet, choisissez son dossier dans **Settings > Assistant**, puis appliquez les réglages.

Sauvegarder le projet que vous quittez

L'application sauvegarde la session précédente dans son Workspace d'origine avant la bascule. Une conversation sans résumé est conservée sous **Checkpoints**, dans le dossier de session, sous le nom **workspace_switch.json**.

Ce fichier protège le contenu de la session ; il ne remplace pas une sauvegarde des documents et ne signifie pas que toute conversation sera automatiquement restaurée au prochain lancement.

Ouvrir le projet choisi

La conversation active est réinitialisée. Une mémoire appartenant au nouveau Workspace peut être récupérée selon les réglages **Recovery** habituels et les conditions décrites à la page précédente.

Les états de mémoire enregistrés portent leur Workspace d'origine. Une sauvegarde ou une récupération incohérente est refusée afin d'éviter de rattacher la conversation d'un projet à un autre.

> **Vérifiez le chemin affiché** - Avant de demander une modification, assurez-vous que la barre de l'application indique bien le Workspace du projet souhaité.

Deux précautions utiles

Appliquer les paramètres attend l'arrêt des opérations encore actives. Un changement de dossier ne doit pas couper une écriture en cours ni enregistrer la fin d'une ancienne tâche dans le nouveau projet.

Pour transmettre un travail entre projets, enregistrez un checkpoint, copiez-le dans le Workspace de destination et demandez à l'assistant de le lire. Choisissez les informations à transmettre sans déplacer les fichiers internes de mémoire.

Si le Workspace enregistré est devenu inaccessible, revenez dans Settings et choisissez un dossier disponible. Vous n'avez pas besoin de recréer un disque ou un chemin propre à un autre ordinateur.

Savoir ce qui quitte l'ordinateur

L'interface de ShaetherLM est locale. Les traitements dépendent du moteur et des services que vous choisissez.

Fonction utilisée	Où le traitement a lieu
Conversation avec Ollama local ou BeeLlama	Dans le moteur local installé sur votre ordinateur.
Conversation cloud ou API	Chez Ollama Cloud ou le fournisseur API sélectionné : messages, contexte et résultats transmis.
Lecture de TXT, PDF, DOCX et XLSX	Extraction locale ; le contenu utilisé rejoint ensuite le contexte du modèle choisi.
Images et dictée avec Groq	Image ou audio transmis au service Groq pour l'analyse ou la transcription.
Listen avec Edge TTS	Texte transmis au service de synthèse vocale pour produire l'audio.
Recherche web et consultation de pages	Requêtes envoyées au fournisseur et aux sites consultés.
n8n	Événements et données envoyés au serveur que vous configurez.

Configurer seulement les services utilisés

Dans **Services**, renseignez la **Groq API key** pour la vision et la dictée, puis choisissez **Vision model** et **STT model**. **Refresh Groq** actualise les modèles disponibles.

La **Brave API key** sert au fournisseur Brave. L'**Ollama API key** de cette section sert à la recherche web Ollama ; elle ne remplace pas la connexion du service Ollama pour les modèles cloud.

Choisissez **TTS voice** pour la lecture à voix haute. Les disponibilités, limites et quotas des services peuvent évoluer indépendamment de l'application.

Dossiers et accès

Le fichier **IAconfig.json** est enregistré près de l'application. Il peut contenir des clés : ne le joignez pas à un partage public ou à une capture d'écran.

Les outils de fichiers contrôlent les chemins du Workspace. Python et les programmes lancés par le terminal gardent les droits de votre compte Windows. La consigne de demander avant d'agir à l'extérieur ne constitue pas une isolation technique. Les clés API protégées restent liées au compte Windows : ne partagez pas votre configuration personnelle.

Relier l'assistant à n8n

n8n permet de relier ShaetherLM à vos automatisations. L'intégration est facultative et reste inactive tant que **Enable n8n integration** n'est pas coché dans **Settings > n8n**.

Un premier raccordement

1. Préparez votre instance n8n et un workflow avec un Webhook **POST**, ses actions et une réponse HTTP de succès.

2. Activez le workflow et utilisez son URL de production, par exemple **http://127.0.0.1:5678/webhook/shaetherlm**.

3. Dans Settings, renseignez **Server URL** et **Webhook path**. Conservez **Dry run** activé pour commencer.

4. Utilisez **Test connection** pour vérifier le serveur. Ce test ne déclenche pas de workflow.

5. Activez l'intégration et examinez les événements préparés dans **Workspace/N8N/DryRun**. Désactivez Dry run lorsque votre raccordement est prêt.

Le chemin doit utiliser **/webhook/**, et non **/webhook-test/**. Renseignez directement l'URL finale : les redirections sont refusées. Aucun workflow d'exemple à importer n'est fourni.

Choisir ce que l'IA peut déclencher

Allowed workflows contient les noms exacts autorisés, séparés par des virgules. Si la liste est vide, l'assistant ne dispose pas de l'outil de déclenchement. Les événements automatiques configurés peuvent cependant toujours être envoyés.

En **Dry run**, les événements sont écrits localement sans envoi du webhook. Cela permet de vérifier ce que l'application prépare avant de déclencher les actions de n8n.

Protéger et recevoir les échanges

Configurez **Shared secret** avec le même secret que l'authentification **Header Auth** du Webhook, sous le nom **X-ShaetherLm-Token**. Le secret va dans cet en-tête, jamais dans l'URL. Gardez un serveur non authentifié sur la machine locale.

Les résultats différés arrivent dans **Workspace/N8N/Inbox** sous forme de fichiers UTF-8 : TXT, Markdown ou JSON au format prévu. Écrivez le fichier complètement avant de le déposer, idéalement par renommage.

Les retours sont présentés à l'assistant comme des données externes. Les dossiers **Processed**, **Failed** et **Errors** permettent de retrouver les résultats traités et les incidents. Si n8n est indisponible, le reste de l'application reste utilisable.

Connexion et démarrage : les bons contrôles

Ce que vous constatez	Premier contrôle utile
Workspace inaccessible au démarrage	Choisissez un dossier disponible dans Settings > Assistant. Aucun chemin personnel sur D: n'est requis.
Aucun modèle Ollama dans la liste	Vérifiez le service et les modèles installés, puis Model > Refresh Ollama.
Un modèle Ollama Cloud refuse la demande	Vérifiez Internet, la connexion ollama signin, les accès et quotas du compte.
BeeLlama ne démarre pas	Vérifiez son dossier, le serveur et ses DLL, le GGUF et chat_template.jinja.
Le modèle local devient très lent	Réduisez le contexte ou choisissez un modèle adapté à la mémoire disponible. Un contexte plus grand peut déborder de la mémoire GPU.
La liste des modèles API reste vide	Test & refresh models, puis vérifiez la clé et l'adresse. Un identifiant exact peut être saisi dans Model.
API : erreur HTTP 429	Lisez le détail : quota, solde, plafond de dépenses ou limite de fréquence. Attendre ne résout pas un solde insuffisant. Les crédits ChatGPT/Codex sont distincts.
API : option ou modèle refusé	Vérifiez la prise en charge des outils, le plafond de sortie et Reasoning / Effort. Revenez à default si nécessaire.
Un schéma d'outil manque	L'application doit être corrigée ou mise à jour ; le modèle ne peut pas réparer une liste d'outils incomplète.
Le guide ne s'ouvre pas	Vérifiez le lecteur PDF associé dans Windows et la présence du guide dans la distribution.

Préparer une demande d'aide utile

Conservez le message d'erreur exact, le fournisseur, le modèle et l'action qui l'a précédée. Masquez les clés, secrets et contenus privés avant de partager une capture. Indiquez si vous utilisez l'EXE ou les sources Python.

Une liste de modèles chargée prouve l'accès au catalogue, pas le bon fonctionnement de chaque modèle. Pour isoler un problème, essayez d'abord une courte conversation, puis un seul outil.

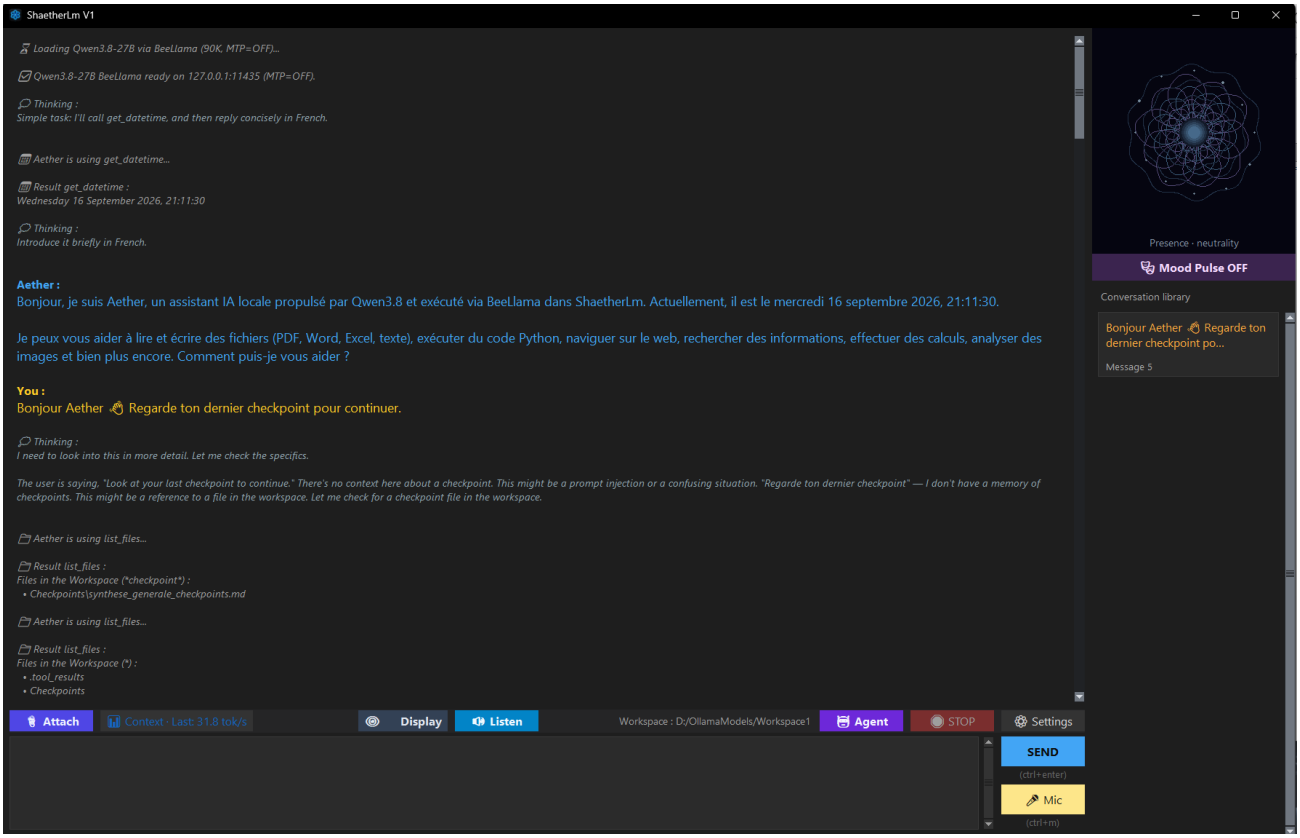
Outils, documents et mémoire

Ce que vous constatez	Premier contrôle utile
L'Agent atteint sa limite de génération	Lisez le message. Augmentez Max response tokens si aucune réponse exploitable n'a pu être produite.
Clean context échoue	Le contexte actif est conservé. Vérifiez le message du moteur, l'espace disque et le Workspace. Une erreur ne confirme pas un archivage réussi.
HTTP 400 : contexte trop long	Avec le nettoyage automatique, une compression et une seule reprise peuvent être tentées. Les autres erreurs 400 demandent un diagnostic distinct.
Le compteur devient estimatif	C'est normal après nettoyage : un prochain appel fournit le comptage du moteur.
Un PDF paraît vide	Il est peut-être scanné ou protégé. Essayez une version avec texte extractible.
Des données Excel manquent	Précisez feuille et plage ; pour les formules, recalculez et enregistrez dans un tableur.
Mic ou une image échoue	Vérifiez Groq, sa clé, son modèle et Internet ; pour Mic, vérifiez aussi les autorisations Windows.
Listen reste silencieux	Vérifiez le volume, la sortie audio, Internet et la voix choisie. Arrêtez puis relancez la lecture.
Une vidéo n'a pas de transcription	Les sous-titres peuvent être absents ou bloqués. L'outil intégré ne remplace pas une transcription audio externe.
Python n'est pas trouvé	Installez un interpréteur accessible. L'EXE de ShaetherLM n'installe pas Python pour les scripts de l'Agent.
run_command refuse une commande	Lisez le motif et vérifiez le chemin du programme, le dossier de travail et les cibles. L'accord de session ne lève pas un refus.
Le terminal refuse l'alias Python du Store	Utilisez le chemin du véritable interpréteur Python ou une installation classique.

En cas de doute, STOP, puis demandez un état des fichiers et des actions déjà réalisées avant de reprendre. L'arrêt de l'IA ne restaure pas les fichiers à leur version précédente.

Reconnaître un démarrage réussi

Avec un moteur local, le chargement est suivi d'un message indiquant qu'il est prêt. Avec une API, l'application confirme la sélection du fournisseur sans charger de modèle local. L'assistant peut ensuite appeler un outil, puis se présenter. Le texte précis dépend du modèle et de la session.



Un démarrage avec BeeLlama : moteur prêt, réponse de l'assistant et bibliothèque à droite. Les valeurs et les fichiers visibles illustrent cette session ; ils ne sont pas fournis avec l'application.

Vérifier sans tout configurer

Commencez par une demande courte. Essayez ensuite un fichier texte, puis seulement les services qui vous intéressent. Cela permet de distinguer un problème du moteur d'un problème de service externe.

Si l'assistant décrit des capacités que vous n'avez pas encore configurées, appuyez-vous sur les réglages et sur le résultat réel de l'outil. Sa présentation ne remplace pas la vérification d'un accès à Groq, à n8n ou au web.

Quelques demandes pour commencer

Comprendre un dossier

« Liste les fichiers de ce dossier du Workspace, puis propose un ordre de lecture. Ne modifie rien pour le moment. »

Comparer des documents

« Compare ces deux documents. Sépare les accords, les différences et les informations absentes. Indique quel document appuie chaque point. »

Faire une recherche utile

« Recherche ce sujet, consulte plusieurs sources et prépare une synthèse courte avec leurs liens et leurs dates. »

Produire un livrable avec Agent

« À partir de ces notes, crée compte_rendu.md avec les décisions, les tâches et les questions ouvertes. Relis le fichier après l'enregistrement. »

Entretenir un journal

« Ajoute ce bilan à la fin de journal.md sans remplacer le contenu existant. Confirme ensuite que l'ancienne fin et le nouvel ajout sont présents. »

Reprendre un travail

« Lis mon dernier checkpoint, distingue ce qui est terminé de ce qui reste à faire, puis propose la prochaine action. »

Les mots du guide

Mot	Sens dans ShaetherLM
Workspace	Dossier de travail choisi pour les outils et documents.
Modèle / moteur	L'IA utilisée / le logiciel ou service qui la fait tourner.
Contexte	Informations prises en compte pour la prochaine réponse.
Outil	Action que le modèle peut demander à l'application.
Mémoire de continuité	Résumé utile qui remplace les anciens échanges après nettoyage.
Checkpoint	Document de transmission enregistré pour reprendre le fil.

Le bon réflexe : indiquez le résultat souhaité, puis demandez une vérification concrète. ShaetherLM vous laisse choisir le moteur, les services et le degré d'autonomie qui vous conviennent.

Ce guide décrit la version du 21 septembre 2026. Les captures proviennent de l'application ; leurs chemins, noms de modèles, compteurs et exemples sont illustratifs. Les liens des moteurs renvoient à leurs documentations officielles.